Optimización Evolutiva de Carteras: Aplicación del Algoritmo Genético en el Mercado Español

Trabajo final de máster Gr.PT-F (43795)

ALUMNO/A: RICARDO ESPAÑA LÓPEZ

TUTOR/A: DRA. ELENA BADAL VALERO

DEPARTAMENTO DEL TUTOR: FINANZAS EMPRESARIALES

CURSO: 2025-2026

FECHA DE DEPÓSITO: 30 DE JUNIO DE 2026

Agradecimientos

Este proyecto es el reflejo de todo lo aprendido, tanto en las aulas como de forma autónoma, a lo largo de estos seis años ininterrumpidos de formación universitaria. Nace de una profunda curiosidad personal, pero su materialización no habría sido posible sin las personas que me han rodeado durante este tiempo.

En primer lugar, a mis profesores y compañeros, por confiar en mí para afrontar problemas complejos y animarme a explorar diferentes soluciones resolverlos. Gracias por darme la oportunidad de participar en proyectos conjuntos; esa exigencia y profesionalidad compartida son las que me han impulsado a crecer.

A mi familia, porque, a pesar de no haber sido el mejor alumno durante gran parte de mi etapa educativa, nunca perdisteis la confianza ni el orgullo en mí. Gracias por acompañarme en el proceso y motivarme a dar siempre lo mejor. En especial para mi abuelo, que hoy me acompaña desde el cielo y sigue guiando mi camino.

A mis amigos y la Comunidad, por haber estado presentes en los momentos de debilidad y darme ese impulso y fe que me ha permitido llegar hasta donde estoy hoy.

Por último, a Virginia. Gracias por ser mi compañera en todo este recorrido y mi pilar fundamental. Has sido tú quien ha iluminado el camino, levantándome en cada tropiezo, ayudándome a encontrar la calma en los momentos de estrés y haciendo que este proceso fuera mucho más llevadero. Por no soltarme nunca de la mano. Eres el motivo por el que busco superarme cada día y la persona junto a la que quiero estar siempre.

Gracias a todos.

Índice general

Resumen **VIII**

Abstract **IX**

1. Introducción **1**
1.1. Motivación del estudio 1
1.2. Planteamiento del Problema 2
1.3. Objetivos 2
1.3.1. Objetivo General 2
1.3.2. Objetivos Específicos 2
1.4. Estructura del Trabajo 3

2. Estado del Arte **5**
2.1. Teoría de la gestión de carteras de Markowitz 5
2.2. Teoría de la Eficiencia de los Mercados 7

3. Marco Teórico **8**
3.1. Evolución y Tipos de Modelos en el Procesamiento de Lenguaje Natural 8
3.1.1. Modelos Transformadores Clásicos 8
3.1.2. El Modelo BERT en el Procesamiento de Lenguaje Natural . . . 9
3.2. Taxonomía Algorítmica: Optimización Heurística e Inteligencia Artificial Explicable (XAI) 10
3.2.1. Optimización Heurística: Algoritmo Genético (AG) 11
3.2.2. Inteligencia Artificial Explicable (XAI) y Modelos Sustitutos (Random Forest) 11

4. Procesamiento de datos y Análisis Exploratorio **13**
4.1. Selección del Universo Inicial 13
4.2. Arquitectura de extracción y procesamiento cuantitativo 14
4.2.1. Datos de Cotización e Indicadores Técnicos 14
4.2.2. Variables Fundamentales y Valoración Intrínseca 16
4.2.3. Entorno Cualitativo 17

4.3. Análisis Exploratorio de los Datos 18
4.3.1. Datos de cotización 18
4.3.2. Datos fundamentales e indicadores técnicos 21
4.3.3. Datos Cualitativos y Procesamiento de Lenguaje Natural (NLP) 24
4.3.4. Procesamiento final de los datos 27

5. Metodología: Algoritmo Genético 29
5.1. Metodología: Entorno de Simulación y Algoritmo Genético 29
5.1.1. Definición del Entorno de Simulación Financiera 29
5.1.2. Algoritmo Genético 31
5.1.3. Parámetros del modelo 31

6. Resultados y Análisis del Algoritmo 33
6.1. Modelo Base: Algoritmo Genético 33
6.1.1. Rendimiento del modelo 33
6.1.2. Rendimiento en el entorno financiero 34
6.1.3. Estructura Interna: Asignación y Correlación de Activos 36
6.2. Estudio de Sensibilidad: Impacto de las Variables Estáticas vs. Dinámicas 38
6.2.1. Rendimiento en el entorno financiero 38
6.3. Modelo sustituto: Random Forest 40
6.3.1. Métricas de validación 41
6.3.2. Explicabilidad de Shap 42
6.4. Prueba de Generalización Cruzada en el S&P 500 43

7. Conclusiones y Léneas Futuras 47
7.1. Conclusiones 47
7.2. Líneas de Investigación Futuras 48

Bibliografía 50

8. Anexo 54
8.1. Anexo: Código 54
8.2. Anexo: Cuadros 56
8.3. Anexo: Figuras 61

Índice de figuras

4.1. Boxplot de los retornos del universo 19
4.2. Max Drawdown de las acciones del universo 20
4.3. Correlaciones de los Indicadores Técnicos 22
4.4. Matrices de correlación cruzada de variables fundamentales 24
4.5. Volumen de noticias por índice bursatil y sector económico 25
4.6. Nivel de saturación y escasez de noticias a nivel de empresa 25
4.7. Distribución de los sentimientos detectados por el modelo de NLP. . . . 26
4.8. Análisis de la confianza del modelo NLP 26
4.9. Relación entre el Score Polarizado de sentimiento y la rentabilidad anualizada. 27

6.1. Evolución del fitness a lo largo de las generaciones 34
6.2. Curva de capital del AG vs Benchmark 35
6.3. Composición y correlación de la cartera AG 37
6.4. Comparativa de modelos en el IBEX 39
6.5. Comparativa de estabilidad de cartera 40
6.6. Explicabilidad de Shap 43
6.7. Generalización de los modelos al S&P 500 44
6.8. Estructura interna de las carteras en el S&P 500 45
6.9. Comparativa de estabilidad de cartera del S&P 500 46

8.1. Heatmap de disponibilidad de datos de cotización 61
8.2. Indicadores Técnicos para la muestra de A3M 62
8.3. Histograma de retornos para cuatro empresas representativas 63
8.4. Mapa Riesgo-Rentabilidad 64
8.5. Histograma de los indicadores técnicos 65
8.6. Correlaciones de fundamentales 66
8.7. Evolución temporal de las publicaciones 66
8.8. Distribución de longitud de texto 67
8.9. Evolución Temporal de la Cartera 68
8.10. Árboles representativos Modelo Sustito 69

Índice de cuadros

4.1. Muestra del Dataframe de cotizaciones 15
4.2. Indicadores Técnicos Calculados para la Formulación del Espacio de Estados 15
4.3. Taxonomía de Variables Fundamentales Extraídas por Grupo Contable 17
4.4. Muestra de extracción de noticias 18

5.1. Hiperparámetros técnicos del Algoritmo Genético y Red Neuronal . . . 32

6.1. Métricas de rendimiento en backtest: AG vs Buy & Hold 36
6.2. Comparativa de Sensibilidad: Modelo Base vs. Modelo Dinámico 39
6.3. Hiperparámetros del Modelo Sustituto 41
6.4. Métricas de Bondad de Ajuste del Modelo Sustituto 42
6.5. Resultados de la Prueba de Generalización Cruzada en el S&P 500 . . . 43

8.1. Listado de empresas por índice, sector e industria 56
8.2. Listado de empresas del S&P500 seleccionadas aleatoriamente 58

Índice de Acrónimos

ADX Average Directional Index (Indicador direccional medio).

AG Algoritmo Genético.

ATR Average True Range (Medida del rango verdadero promedio de volatilidad).

BB Bollinger Bands (Bandas de Bollinger) .

BERT Bidirectional Encoder Representations from Transformers.

CAGR Rentabilidad Anualizada (Compound Annual Growth Rate).

CAPM Capital Asset Pricing Model (Modelo de valoración de activos financieros).

CMA Conservative Minus Aggressive (Factor de patrón de inversión).

CML Capital Market Line (Frontera eficiente o línea del mercado de capitales) .

CV Validación Cruzada (Cross Validation).

DRL Deep Reinforcement Learning (Aprendizaje por refuerzo profundo).

EBIT Beneficio antes de intereses e impuestos (Earnings Before Interest and Taxes).

EBITDA Beneficio antes de intereses, impuestos, depreciaciones y amortizaciones .

EDA Análisis Exploratorio de Datos.

EMA Media móvil exponencial.

GPT Generative Pre-trained Transformer.

HEM Hipótesis de la Eficiencia de los Mercados.

HML High Minus Low (Factor valor o relación entre el valor contable y el de mercado).

MACD Convergencia y divergencia de medias móviles (Moving Average Convergence Divergence).

MDD Max Drawdown.

MDP Proceso de Decisión de Markov.

MLM Masked-Language-Model.

MLP Perceptrón Multicapa (Multilayer Perceptron).

MSE Error Cuadrático Medio (Mean Squared Error).

NLP / PLN Procesamiento de Lenguaje Natural.

NSP Next-Sentence-Prediction.

OBV On-Balance Volume (Flujo de volumen acumulado).

OHLCV Apertura, Máximo, Mínimo, Cierre y Volumen.

PER / P_E Price-to-Earnings Ratio (Múltiplo de valoración sobre beneficios).

PPO Proximal Policy Optimization.

RMSE Raíz del Error Cuadrático Medio (Root Mean Square Error).

RMW Robust Minus Weak (Factor de rentabilidad operativa).

RSI Relative Strength Index (Oscilador de momento).

SHAP SHapley Additive exPlanations.

SMA Media móvil simple (Simple Moving Average).

SMB Efecto Tamaño (Small Minus Big)

Resumen

Este proyecto aborda las limitaciones de la gestión tradicional y los sesgos humanos diseñando un agente algorítmico autónomo capaz de generar estrategias de inversión endógenas. Aplicado sobre un universo representativo del mercado español (índices IBEX 35, Medium Cap y Small Cap), el modelo busca optimizar la asignación de activos respetando restricciones operativas reales, como un límite estricto de cardinalidad.

A nivel metodológico, el entorno de simulación integra tres capas de información: indicadores técnicos, variables fundamentales y análisis de sentimiento financiero mediante NLP. El núcleo de decisión es un Algoritmo Genético que optimiza una población de estrategias para maximizar el ratio de Sharpe (Chang et al., 2000). Para dotar de transparencia a esta *caja negra*, el estudio emplea Inteligencia Artificial Explicable (XAI) entrenando un modelo sustituto Random Forest, lo cual permite usar valores SHAP para desglosar qué variables motivan cada decisión de inversión (Xu et al., 2025).

Los resultados muestran que este enfoque híbrido supera a los modelos basados únicamente en el precio. El análisis revela que el agente prioriza sistemáticamente las métricas contables como estabilizadores para defenderse de la volatilidad. Por el contrario, al forzar al algoritmo a operar solo con datos técnicos, este sufre hiperreactividad y pérdidas más severas. Finalmente, una prueba de generalización sobre el S&P 500 comprobó que la lógica aprendida no presenta sobreajuste local, adaptándose con éxito a las dinámicas de un mercado extranjero distinto.

Palabras clave: Optimización de Carteras, Algoritmo Genético, Procesamiento de Lenguaje Natural, Random Forest, Mercado Español.

Abstract

This project addresses the limitations of traditional management and human biases by designing an autonomous algorithmic agent capable of generating endogenous investment strategies. Applied to a representative sample of the Spanish market (IBEX 35, Medium Cap, and Small Cap indices), the model seeks to optimize asset allocation while respecting real-world operational constraints, such as a strict cardinality limit.

Methodologically, the simulation environment integrates three layers of information: technical indicators, fundamental variables, and financial sentiment analysis using Natural Language Processing (NLP). The core decision-making tool is a Genetic Algorithm that optimizes a population of strategies to maximize the Sharpe ratio (Chang et al., 2000). To bring transparency to this *black box*, the study employs Explainable Artificial Intelligence (XAI) by training a Random Forest surrogate model, which allows the use of SHAP values to break down which variables motivate each investment decision (Xu et al., 2025).

The results demonstrate that this hybrid approach outperforms models based solely on price. The analysis reveals that the agent systematically prioritizes accounting metrics as stabilizers to protect against volatility. Conversely, forcing the algorithm to operate solely on technical data causes it to become overly reactive and experience more severe losses. Finally, a generalization test on the S&P 500 confirmed that the learned logic does not exhibit local overfitting, successfully adapting to the dynamics of a different foreign market.

Keywords: Portfolio Optimization, Genetic Algorithm, Natural Language Processing, Random Forest, Spanish Stock Market.

Capítulo 1

Introducción

1.1. Motivación del estudio

En las últimas décadas, los mercados financieros han experimentado una transformación radical impulsada por la digitalización, el incremento exponencial en la disponibilidad de datos y el avance de las ciencias de la computación. En este contexto, la gestión de carteras y la generación de estrategias de inversión han evolucionado desde el análisis técnico y fundamental tradicional hacia enfoques puramente cuantitativos. Dentro de esta corriente, la gestión pasiva ha ganado un enorme terreno, consolidándose como la referencia estándar debido a su eficiencia en costes y a la dificultad histórica que muestran los gestores activos para batir de forma consistente a los índices de mercado (D'Hondt et al., 2020).

Sin embargo, el auge del *Machine Learning* y los métodos computacionales han abierto una nueva ventana en las finanzas (Brenner y Meyll, 2020). Estos modelos, comúnmente clasificados como *caja negra* debido a la complejidad de sus estructuras internas y a la naturaleza no lineal de sus aproximaciones, ofrecen una agilidad para identificar patrones ocultos en series temporales ruidosas y complejas. A diferencia de los sistemas basados en reglas rígidas o indicadores técnicos tradicionales sujetos a una interpretación subjetiva, estos algoritmos tienen la capacidad de procesar grandes volúmenes de información multidimensional y adaptar sus decisiones con facilidad.

Este trabajo se enmarca en la intersección entre la teoría financiera clásica y la utilización de modelos computacionales, explorando el potencial de los modelos de caja negra como herramientas autónomas para la toma de decisiones óptimas en la asignación de activos y la ejecución de órdenes de compra y venta en renta variable (Jang y Seong, 2023; Jiang et al., 2017).

1.2. Planteamiento del Problema

El principio fundamental de la Hipótesis de la Eficiencia de los Mercados (Fama, 1970) sugiere que los precios de los activos reflejan plenamente toda la información disponible, lo que implica que batir al mercado de forma sistemática en el largo plazo sin asumir un riesgo desproporcionado no es compatible frente a esta teoría (Sheptyuk Riabchynskiy, 2025). Por ello, la gestión pasiva se ha erigido como la estrategia óptima para el inversor promedio, tomando como referencia índices de referencia sobre los cuales invertir (Luo et al., 2024; Perlin et al., 2025).

El problema surge cuando la gestión activa tradicional intenta batir estos índices. Dicha gestión se enfrenta a dos limitaciones: por un lado, los sesgos cognitivos y emocionales de los operadores humanos, que distorsionan la ejecución de las estrategias en momentos de alta volatilidad; por otro lado, la incapacidad de las herramientas estadísticas clásicas (como los modelos autorregresivos lineales) para capturar las dinámicas no lineales y los cambios de régimen que caracterizan a los activos financieros.

Si bien la literatura reciente ha demostrado que el uso de algoritmos de aprendizaje automático puede mejorar la predicción de tendencias, la mayoría de estos enfoques siguen dependiendo de instrucciones previas y restricciones estrictas de diseño humano (Ambuli et al., 2024). El verdadero desafío planteado radica en responder a la siguiente pregunta: *¿Es posible diseñar un agente algorítmico puramente autónomo que, partiendo desde cero y sin ningún tipo de regla preestablecida de forma ex´gena, sea capaz de asimilar la complejidad del mercado y formular una estrategia de inversión robusta?*

1.3. Objetivos

1.3.1. Objetivo General

El objetivo principal de esta investigación es diseñar, implementar y comprobar el funcionamiento de un sistema automatizado basado en un modelo de *caja negra* capaz de generar señales autónomas de compra y venta en el mercado IBEX, evaluando su capacidad operativa al contrastar su rendimiento frente a los índices de referencia y el *Buy & Hold* equiponderado del IBEX 35 [1].

1.3.2. Objetivos Específicos

Para dar cumplimiento al objetivo general, se plantean los siguientes objetivos específicos:

[1] El desarrollo del proyecto se ha guardado en un repositorio público de Github para comprobar la reproducibilidad del proyecto.

- **Creación del universo del agente:** Crear desde cero el universo sobre el cual se va a realizar el estudio, no solo basándose en datos de cotización, sino también variables fundamentales de las empresas incorporadas en el universo, así como otorgar un análisis del sentimiento sobre los datos cualitativos extraídos.

- **Desarrollar e implementar el algoritmo de caja negra:** Configurar la arquitectura del modelo de aprendizaje para que procese las series temporales financieras, lea toda la información disponible del universo creado y operar con todas las acciones de este, pero estando sujeto a un límite de cardinalidad de 9 acciones más efectivo en la cartera.

- **Valorar la calidad y autonomía de la estrategia formulada:** Analizar las pautas y decisiones de inversión adoptadas por el algoritmo, determinando la lógica financiera subyacente que el modelo desarrolla de forma endógena, sin haber recibido instrucciones o reglas operativas previas.

- **Evaluar la robustez y la relación riesgo-rendimiento:** Contrastar el desempeño del modelo a través de métricas financieras para garantizar que los retornos obtenidos no se derivan de una exposición excesiva al riesgo, sino de una gestión ágil y consistente de la cartera.

1.4. Estructura del Trabajo

Para dar respuesta a los objetivos planteados, el documento se organiza de la siguiente manera:

El **Capítulo 2** expone el estado del arte, revisando las teorias financieras clásicas, como la teoría de la gestión de carteras de Markowitz y la Hipótesis de la Eficiencia de los Mercados. A continuación, el **Capítulo 3** desarrolla el marco teórico, abordando la evolución de los modelos de Procesamiento de Lenguaje Natural, la optimización heurística mediante algoritmos genéticos y la implementación de Inteligencia Artificial Explicable a través de un modelo sustituto.

El **Capítulo 4** detalla todo el proceso de selección, extracción y procesamiento de los datos (técnicos, fundamentales y cualitativos), presentando además un análisis exploratorio del universo de activos. Posteriormente, el **Capítulo 5** define la arquitectura metodológica, describiendo formalmente el entorno de simulación financiera y la parametrización del Algoritmo Genético.

El **Capítulo 6** recoge los resultados empíricos, evaluando el rendimiento del modelo base, realizando un estudio de sensibilidad al aislar los datos técnicos, interpretando las decisiones mediante explicabilidad de los valores de SHAP y comprobando la generalización cruzada del agente en el S&P 500. Finalmente, el **Capítulo 7** presenta las

conclusiones finales extraídas de la investigación y propone diversas líneas de trabajo futuras.

Capítulo 2

Estado del Arte

El desarrollo de sistemas de inversión autónomos basados en *cajas negras*, no surge de forma aislada, sino como una evolución necesaria frente a las limitaciones de los paradigmas financieros y estadísticos tradicionales, los cuales resultan insuficientes para procesar la complejidad y no linealidad de los datos actuales (Bhuiyan et al., 2025; López De Prado, 2020). Para comprender el verdadero valor y el desafío que supone aplicar modelos de *caja negra* o *Deep Learning* para batir a la gestión pasiva (Moosa et al., 2024), se deben establecer previamente las bases teóricas que han dominado la asignación de activos y la concepción de los mercados durante más de medio siglo Chang et al., 2000. En este sentido, el presente apartado explora los pilares de la gestión clásica introducida por Markowitz y Fama, al igual que las asunciones tradicionales sobre la eficiencia de los precios, construyendo el marco de referencia que los algoritmos de aprendizaje automático y optimización pretenden desafiar en la actualidad Jang y Seong, 2023. .

2.1. Teoría de la gestión de carteras de Markowitz

La teoría sobre la gestión de carteras, formulada por Markowitz (1959) representó una revolución en el ámbito financiero. Anterior a este desarrollo, la estrategia de inversión se concentraba en el análisis independiente de cada activo, donde se valoraban elementos como el desempeño histórico, la solidez financiera de la empresa y las proyecciones del sector. Este enfoque tradicional omitía la interacción entre las distintas inversiones en una misma cartera, un método que, no proporcionaba una perspectiva completa sobre el potencial y los riesgos reales de una inversión.

Con la introducción de esta teoría, Markowitz destacó la relevancia de diversificar y entender la correlación entre los activos dentro de una cartera. Específicamente, introdujo dos conceptos clave que cambiarían el paradigma de la gestión de carteras: *la diversificación* y *la correlación* entre los activos. A diferencia del enfoque previo

centrado en la rentabilidad individual, el autor propuso que al combinar activos con correlaciones bajas o negativas se podría disminuir el riesgo global de la cartera sin comprometer su rendimiento esperado.

Su teoría subrayó la importancia de evaluar cómo los activos interactúan entre sí bajo diversas condiciones del mercado. Para formalizar esto, se presentó un modelo cuantitativo riguroso, la optimización media-varianza para la selección de carteras que equilibra el riesgo y el retorno. Este marco teórico, basado en la aplicación de ideas matemáticas al problema de la formulación de inversiones, permitía a los inversores racionales calcular la combinación óptima de activos considerando simultáneamente el rendimiento esperado y el riesgo, medido a través de la volatilidad o variabilidad de los retornos. Esta innovación modificó profundamente el método utilizado por inversores y gestores para evaluar los activos financieros y sentó las bases para los futuros avances en la gestión cuantitativa de inversiones.

Aunque el marco de media-varianza sentó las bases teóricas de la optimización, la comprensión sobre qué variables determinan realmente el rendimiento esperado de esos activos continuó evolucionando para capturar diversas anomalías de los precios que la teoría clásica no podía explicar. En esta línea de evolución, Fama y French (2015) propusieron su modelo de cinco factores, el cual representa un avance significativo al ampliar su clásico modelo de tres factores de 1993 incorporando nuevos patrones fundamentales que inciden directamente en los rendimientos bursátiles. Este modelo multifactorial establece que el rendimiento de una cartera no solo depende de su riesgo frente al mercado global, sino que se explica a través de la exposición a cinco dimensiones de riesgo clave: el riesgo de mercado ($R_M - R_F$), el tamaño de la empresa (*Small Minus Big*, SMB), el factor valor o relación entre el valor contable y el de mercado (*High Minus Low*, HML), la rentabilidad operativa (*Robust Minus Weak*, RMW) y el patrón de inversión (*Conservative Minus Aggressive*, CMA). La inclusión metodológica de la rentabilidad y la inversión permitió capturar características del mercado donde empresas que invierten agresivamente a pesar de su baja rentabilidad generan bajos rendimientos promedio, demostrando empíricamente que las firmas rentables y con políticas de crecimiento de activos conservadoras tienden a generar retornos superiores. Esta teoría enriqueció el análisis de carteras moderno al proporcionar a los gestores e investigadores un modelo mucho más completo y preciso, capaz de explicar una mayor proporción de la varianza transversal en los retornos esperados de las carteras para evaluar la calidad de los activos y optimizar la asignación de capital (Serur y Avellaneda, 2020).

2.2. Teoría de la Eficiencia de los Mercados

La Hipótesis de la eficiencia de los mercados (HEM), formalizada por Fama (1970) y por la que obtuvo el premio Nobel, ha sido uno de los paradigmas centrales en la teoría financiera clásica. Esta hipótesis mantiene que toda la información relevante se refleja de manera inmediata, precisa y completa en los precios de los activos financieros. Bajo este marco teórico, se asume que los mercados cotizan los activos en su "valor justo" y que los individuos que participan en ellos son agentes homogéneos y perfectamente racionales (Beyhan y Ulengin, 2023). En consecuencia, la HEM sugiere que resulta imposible predecir de forma consistente los movimientos futuros de los precios basándose en información histórica, lo que invalidaría tanto la utilidad del análisis técnico como cualquier estrategia diseñada para obtener rentabilidades superiores a las del mercado de manera sistemática (Beyhan y Ulengin, 2023; Fama, 1970).

Sin embargo, a lo largo de las últimas décadas, la creciente complejidad del sistema financiero ha desafiado de manera directa las suposiciones de esta teoría. Diversos estudios han demostrado que los mercados no siempre operan con eficiencia perfecta, ya que el comportamiento de los inversores suele estar condicionado por sesgos cognitivos, emociones colectivas y reacciones irracionales. Esta limitación ha sido ampliamente documentada por las finanzas conductuales, impulsadas por enfoques como la "Teoría de las Perspectivas" introducida por Kahneman y Tversky (1979).

En la actualidad, la comprensión de que los mercados financieros sufren anomalías, poseen memoria a corto plazo y presentan dinámicas altamente no lineales, constituye la principal justificación teórica para el desarrollo de estrategias de *trading* algorítmico que traten de captar los movimientos futuros. La incapacidad de la HEM para explicar completamente la realidad bursátil es precisamente lo que abre la puerta a la implementación de modelos de Inteligencia Artificial. Algoritmos complejos de *Machine Learning* y optimización se desarrollan hoy en día para identificar e interceder en esas ineficiencias temporales, extrayendo patrones ocultos y relaciones no lineales que las teorías clásicas asumen inexistentes (Sheptyuk Riabchynskiy, 2025). Es en esta brecha metodológica donde se fundamenta el propósito de este trabajo: diseñar un agente algorítmico que, libre de las restricciones y sesgos de la gestión tradicional, sea capaz de explotar dichas ineficiencias en el entorno específico creado para buscar una rentabilidad superior.

Capítulo 3

Marco Teórico

3.1. Evolución y Tipos de Modelos en el Procesamiento de Lenguaje Natural

La capacidad de un agente algorítmico para tomar decisiones óptimas en los mercados financieros depende intrínsecamente de la riqueza, dimensionalidad y calidad de la información que compone su entorno observable. Tradicionalmente, los modelos se han alimentado de manera exclusiva de series temporales numéricas, limitando su visión a la evolución histórica de los precios o los volúmenes de negociación (Alfzari et al., 2025). Sin embargo, en este proyecto se ha buscado darle la visión cualitativa que *a priori* no es observable para un algoritmo. Es en este punto donde el Procesamiento de Lenguaje Natural (PLN) cobra una relevancia metodológica considerable. Mediante la aplicación de estas técnicas, resulta posible automatizar el análisis de sentimiento sobre un vasto volumen de noticias financieras y eventos corporativos extraídos para el universo de activos. La extracción de este conocimiento textual puede permitir cuantificar en cierta medida las expectativas del mercado y el impacto mediático, integrándolos como una variable que enriquece el espacio de estados del algoritmo (Yang et al., 2024). Por consiguiente, para comprender cómo se procesa esta información no estructurada, a continuación se detallan los fundamentos teóricos y la evolución de los modelos de lenguaje que hacen posible su cuantificación.

3.1.1. Modelos Transformadores Clásicos

La principal innovación de la arquitectura de los transformadores es que prescinde por completo de la recurrencia y las convoluciones, apoyándose exclusivamente en mecanismos de autoatención. La autoatención permite relacionar diferentes posiciones de una misma secuencia para calcular una representación conjunta de la misma (Vaswani et al., 2023). Este salto arquitectónico posibilitó el análisis en paralelo de dependen-

cias contextuales a larga distancia dentro del texto, superando así el cuello de botella que suponía el cómputo secuencial inherente a las arquitecturas recurrentes (Cano y Sánchez, 2024).

La transición hacia un procesamiento paralelo no solo redujo significativamente los tiempos de entrenamiento y los costos computacionales para secuencias largas, sino que permitió una paralelización mucho mayor de los procesos. Como resultado, estos modelos clásicos lograron mejoras notables en la precisión para tareas fundamentales del PLN, estableciendo nuevos estándares de rendimiento en áreas como la traducción automática, el análisis sintáctico y el resumen automático de textos (Vaswani et al., 2023).

En última instancia, el diseño de estos modelos transformadores clásicos sentó las bases estructurales que permitieron la creación de los grandes modelos de lenguaje preentrenados y altamente escalables que dominan la actualidad, tales como la familia bidireccional BERT (*Bidirectional Encoder Representations from Transformers*) y la familia autorregresiva GPT (*Generative Pre-trained Transformer*)(Cano y Sánchez, 2024).

3.1.2. El Modelo BERT en el Procesamiento de Lenguaje Natural

Fundamentos y Arquitectura

El modelo BERT (*Bidirectional Encoder Representations from Transformers*), introducido por Google (Devlin et al., 2019), representa un hito fundamental en el Procesamiento de Lenguaje Natural (PLN) moderno. A diferencia de los enfoques unidireccionales o secuenciales previos, BERT introdujo el paradigma bidireccional, lo que permite al modelo capturar el contexto de una palabra leyendo la secuencia de texto tanto de izquierda a derecha como de derecha a izquierda simultáneamente. Esta arquitectura se basa en las redes neuronales (*Transformers*) y utiliza de forma intensiva el mecanismo de (*self-attention*) para establecer representaciones vectoriales profundas. A nivel estructural, un modelo base de BERT suele componerse de 12 capas de autoatención con 12 cabezales de atención cada una y un tamaño oculto de 768, alcanzando aproximadamente 110 millones de parámetros (Devlin et al., 2019).

Mecanismos de Aprendizaje: MLM y NSP

El éxito de BERT radica en sus tareas de preentrenamiento no supervisado utilizando corpus masivos de texto, como Wikipedia. Devlin et al. (2019) secciona el entrenamiento de estos modelos principalmente endos tareas:

- **Masked-Language-Model (MLM):** El modelo corrompe la secuencia de entrada ocultando o eliminando arbitrariamente algunos tokens (palabras o subpalabras) y se entrena para predecir y reconstruir la secuencia original basándose únicamente en el contexto bidireccional .

- **Next-Sentence-Prediction (NSP):** El modelo aprende a predecir si una oración A es seguida lógicamente por una oración B en el texto original, lo cual es crucial para tareas que requieren entendimiento de relaciones entre oraciones, como la respuesta a preguntas .

Variantes, Especialización de Dominio y Aplicación Financiera

La versatilidad de la arquitectura BERT ha fomentado la creación de modelos entrenados en corpus de dominios específicos para mejorar el rendimiento frente a vocabularios técnicos. Asimismo, para mitigar la disminución de rendimiento que a veces sufren los modelos multilingües masivos. La comunidad ha desarrollado variantes monolingües puras. Para el idioma español, destaca formalmente el modelo **BETO** (Cañete et al., 2023).

En el marco de esta investigación, y con el objetivo de dotar al agente de una métrica de entrada precisa y adaptada al léxico corporativo, se ha implementado el modelo especializado **finance-sentiment-es** (bards.ai, 2024). Esta arquitectura toma como base las capacidades bidireccionales del transformador adaptadas al español y ha sido sometida a un proceso de *fine-tuning* específico mediante el uso del *Financial PhraseBank* traducido. Esto permite resolver con rigurosidad las particularidades semánticas de la jerga financiera y emitir clasificaciones de sentimiento óptimas para el universo de activos considerado.

3.2. Taxonomía Algorítmica: Optimización Heurística e Inteligencia Artificial Explicable (XAI)

Tal y como se ha expuesto anteriormente, la superación de las ineficiencias del mercado y las limitaciones propias de la gestión pasiva requiere el despliegue de modelos computacionales avanzados que no dependan del juicio humano ni de las premisas lineales clásicas. La principal razón para estructurar e implementar esta diversidad algorítmica en el ámbito financiero radica en su capacidad para modelar la cartera bajo las restricciones operativas del mundo real como sortear los sesgos cognitivos de los inversores, parametrizando oportunidades de inversión óptimas que resultarían matemáticamente intratables o invisibles para los modelos analíticos clásicos (Chang et al., 2000).

En este contexto empírico, este trabajo estructura una aproximación metodológica dual para la gestión de carteras: en primer lugar, la generación autónoma de señales de inversión mediante un algoritmo evolutivo heurístico; y en segundo lugar, la disección de su lógica interna del modelo mediante la implementación de un modelo sustituto *Random Forest* utilizado para aplicar la Inteligencia Artificial Explicable (XAI). A continuación, se definen conceptualmente ambas aproximaciones.

3.2.1. Optimización Heurística: Algoritmo Genético (AG)

La gestión de carteras impone desafíos geométricos particulares. Según Chang et al. (2000), el modelo clásico de Media-Varianza de Markowitz (1959) se resuelve de forma eficiente mediante programación cuadrática continua. Sin embargo, la incorporación de restricciones operativas reales en este estudio, como es el límite estricto de cardinalidad altera por completo la geometría del espacio de búsqueda, transformando la frontera eficiente en un conjunto discontinuo e irregular.

Para sortear esta barrera analítica, Gilli y Këllezi (2004) resaltan el uso de algoritmos evolutivos dentro de la optimización heurística. Para este trabajo, se despliega un *Algoritmo Genético (AG)*, una heurística de búsqueda poblacional inspirada en los principios de la evolución biológica y la selección natural. Su funcionamiento difiere radicalmente de las aproximaciones analíticas de gradiente continuo:

- En lugar de modificar parámetros a través de derivadas, el AG codifica cada solución candidata (la estructura de ponderaciones de la cartera) en una estructura digital equivalente a un "cromosoma".

- El algoritmo evalúa de forma iterativa la aptitud (*fitness*) de una población de carteras frente a los datos del universo de mercado, y propaga la información de las combinaciones más eficientes a través de operadores matemáticos de cruce (*crossover*) y mutaciones aleatorias, permitiendo escapar de óptimos locales en espacios de búsqueda altamente no convexos.

3.2.2. Inteligencia Artificial Explicable (XAI) y Modelos Sustitutos (Random Forest)

A pesar de la probada eficacia de los algoritmos genéticos para encontrar soluciones robustas en entornos complejos, su principal limitación en el ámbito cuantitativo financiero es su opacidad (Jang y Seong, 2023; Sheptyuk Riabchynskiy, 2025). La naturaleza intrínseca del AG lo convierte en una *caja negra*, lo que imposibilita conocer de forma directa qué variables del mercado han motivado una asignación de pesos específica. Esta falta de explicabilidad y transparencia dificulta enormemente la auditoría de riesgos y la adopción de estas estrategias (Molnar et al., 2020).

Para resolver este paradigma, se integra la disciplina de la *Inteligencia Artificial Explicable (XAI)*. En este estudio, en lugar de utilizar algoritmos de *Machine Learning* para predecir precios futuros, se implementa un modelo *Random Forest* con el propósito de actuar como un modelo sustituto capaz de explicar el comportamiento del modelo genético.

El *Random Forest* es un método de aprendizaje supervisado basado en la construcción conjunta de múltiples árboles de decisión, y, en este caso, se entrena para replicar el comportamiento del Algoritmo Genético. Toma como entradas el mismo conjunto de características multidimensionales y como variable objetivo las ponderaciones de cartera que el AG ha decidido generar en cada paso temporal.

Una vez que el modelo sustituto alcanza una alta fidelidad estadística respecto al agente original mediante medidas de bondad de ajuste, se calculan los valores **SHAP** (*SHapley Additive exPlanations*) propuestos por Lundberg y Lee (2017). Apoyada en la teoría de juegos cooperativos, esta técnica permite desglosar y cuantificar la contribución marginal exacta de cada variable dinámica y estática en la toma de decisiones, revelando la lógica subyacente del modelo.

La arquitectura evolutiva permite encontrar configuraciones de inversión óptimas sorteando las restricciones de cardinalidad impuestas por el mercado. Por su parte, la integración del Random Forest como modelo sustituto aporta la capa analítica de transparencia necesaria para auditar las decisiones del agente (Lundberg y Lee, 2017; Moosa et al., 2024). Este diseño metodológico conjunto tiene como propósito fundamental determinar la viabilidad real de generar señales de compra y venta autónomas que superen la gestión pasiva tradicional en el universo marcado, garantizando un control auditable e interpretable sobre los factores subyacentes que motivan cada movimiento de la cartera (Perlin et al., 2025).

Capítulo 4

Procesamiento de datos y Análisis Exploratorio

4.1. Selección del Universo Inicial

La selección de activos se ha basado en utilizar los componentes de los tres indices principales del mercado español, IBEX 35, IBEX Medium Cap e IBEX Small Cap. La selección conjunta de estos índices como universo de estudio se ha basado en la metodologia de Sheptyuk Riabchynskiy (2025), dado que busca responder a la necesidad de construir una muestra exhaustiva y estructuralmente representativa del mercado continuo español. Esta integración permite analizar el comportamiento financiero a través de todo el espectro de capitalización bursátil y liquidez.

La selección de este universo busca cuatro características relevantes para el estudio:

- **Diversificación sectorial y de tamaño**: Utilizar las empresas componentes de estos índices implica utilizar diferentes niveles de capitalización bursátil. De esta forma, el universo no se encuentra sesgado por las *Large Caps* del IBEX 35, dominadas por el sector financiero y energético.

- **Diferentes espectros de liquidez**: La presencia de activos más liquidos como son los del IBEX 35 junto con con empresas de menor capitalización permiten aportar diferentes perfiles de liquidez, mostrandole al agente gestor un entorno más heterogéneo.

- **Escalabilidad y robustez**: Trabajar con un universo de 85 acciones ofrece un equilibrio óptimo entre la robustez estadística necesaria para poder validar las decisiones de inversión.

De este modo, el estudio logra contrastar empíricamente tres perfiles de riesgo-rentabilidad bien diferenciados: la estabilidad defensiva y alta liquidez de los gigantes corporativos

(Large Caps), el equilibrio entre consolidación y crecimiento de las empresas medianas (Mid Caps), y la alta volatilidad inherente a las compañías de pequeña capitalización (Small Caps), cuyo atractivo radica en la búsqueda de alfa y el crecimiento exponencial. La composición de los tres índices es la referida al 31 de Marzo de 2026 en el cuadro (8.1).

4.2. Arquitectura de extracción y procesamiento cuantitativo

Para que el modelo pueda emitir señales de compra y venta precisas, necesita observar el mercado a través de una matriz de datos multidimensional. Con este fin, se ha implementado un proceso de extracción y procesamiento de los datos estructurado en tres dimensiones analíticas: la acción del precio (técnica), la valoración intrínseca (fundamental) y el sentimiento del mercado (cualitativa). La información recogida para cotizaciones y noticias abarca el periodo el 1 de enero de 2021 y el 31 de diciembre de 2025, mientras que las variables fundamentales se recogen un año anterior para no cometer un *look-ahead* a la hora de procesar el conjunto de datos final. [1]

4.2.1. Datos de Cotización e Indicadores Técnicos

La primera capa de información dota al agente de su capacidad para detectar tendencias y regímenes de volatilidad a corto plazo. Mediante la `LSEG Data Library` (London Stock Exchange Group, 2026), se extrajeron las series históricas diarias *OHLCV* (Apertura, Máximo, Mínimo, Cierre y Volumen) para todo el universo de activos utilizando la clasificación sectorial y los identificadores institucionales correspondientes de Thomson Reuters, 2016.

Despues de obtener los precios crudos de cotización de los activos del universo, se aplicó una transformación vectorial para calcular una batería de indicadores técnicos, englobando osciladores de momento, medidores de tendencia, métricas de volatilidad y flujo de volumen (OBV). La motivación de este procesamiento radica en estructurar matemáticamente el comportamiento del activo, traduciendo las oscilaciones gráficas en un espacio de estados continuo que el algoritmo pueda evaluar de forma estacionaria para optimizar sus políticas de inversión. Los datos se pueden ver en el cuadro 4.1.

[1] La arquitectura de extracción y procesamiento de los datos puede consultarse en el repositorio del proyecto detallado en el Anexo 8.1.

Cuadro 4.1: Muestra del Dataframe de cotizaciones. Fuente: Elaboración propia

Date	RIC	Ticker	Sector	Open	High	Low	Close	Volume
2021-01-04	A3M.MC	A3M	Consumer Cyclicals	2,888	2,940	2,860	2.886	321.488
2021-01-05	A3M.MC	A3M	Consumer Cyclicals	2,880	2,982	2,878	2.940	390.326
2021-01-06	A3M.MC	A3M	Consumer Cyclicals	2,978	3,174	2,956	3.124	582.687
2021-01-07	A3M.MC	A3M	Consumer Cyclicals	3,102	3,146	3,074	3.110	274.068
2021-01-08	A3M.MC	A3M	Consumer Cyclicals	3,114	3,114	3,038	3.074	245.979

Nota: Se muestran las cinco primeras observaciones del panel de datos limpio. Se han omitido las variables descriptivas de 'Nombre', 'Industria' e 'Indice' en esta visualización por motivos de espacio, manteniendo las variables cuantitativas principales (OHLCV). **Fuente:** Elaboración propia.

Una vez se define el DataFrame de cotizaciones, en el cuadro 4.2 se esclarecen cuales son los indicadores técnicos elaborados con el paquete de python `ta` ((GranData), 2020).

Cuadro 4.2: Indicadores Técnicos Calculados para la Formulación del Espacio de Estados.

Familia	Indicador	Fórmula	Descripción
Momento	RSI (14)	$RSI = 100 - \frac{100}{1+RS}$	Cuantifica la magnitud de los movimientos recientes del precio para identificar potenciales condiciones de sobrecompra o sobreventa del activo.
	Estocástico	$\%K = \frac{C_t - L_{14}}{H_{14} - L_{14}} \times 100$	Evalúa la posición del precio de cierre actual (C_t) en relación con su rango histórico de máximos (H_{14}) y mínimos (L_{14}) recientes.
Tendencia	MACD	$MACD = EMA_{12} - EMA_{26}$	Mide la convergencia y divergencia entre medias móviles exponenciales (EMA) para aislar cambios en el momentum direccional.
	ADX (14)	$ADX = 100 \times EMA\left(\frac{\lvert +DI - -DI \rvert}{+DI + -DI}\right)$	Determina la fuerza subyacente de la tendencia vigente, independientemente de la dirección que tome el activo.
	SMA (50, 200)	$SMA_n = \frac{1}{n}\sum_{i=1}^{n} C_{t-i}$	Suaviza la serie de precios original para aislar la tendencia macroestructural a medio y largo plazo.
Volatilidad	Bollinger (20,2)	$Bands = SMA_{20} \pm 2\sigma$	Define canales de desviación estándar (σ) dinámicos en torno al precio para evaluar la dispersión y la volatilidad implícita del mercado.

Continúa en la página siguiente...

Cuadro 4.2: Indicadores Técnicos Calculados para la Formulación del Espacio de Estados (continuación)

Familia	**Indicador**	**Fórmula**	**Descripción**
	ATR (14)	$ATR_t = \frac{1}{n}\sum_{i=1}^{n} TR_{t-i}$	Mide el rango verdadero promedio (TR), capturando la volatilidad absoluta diaria y contabilizando los huecos de apertura.
Volumen	OBV	$OBV_t = OBV_{t-1} \pm V_t$	Flujo de volumen (V) acumulado que correlaciona directamente la presión compradora o vendedora con las variaciones del cierre.

Fuente: Elaboración propia a partir del trabajo de Sheptyuk Riabchynskiy (2025).

4.2.2. Variables Fundamentales y Valoración Intrínseca

Si bien los indicadores técnicos rigen las decisiones a corto plazo, un agente gestor autónomo requiere anclar sus decisiones a la realidad contable de las empresas para evitar invertir en activos sobrevalorados o estructuralmente deficientes. Para aportar esta dimensión de "valor intrínseco", se extrajeron métricas fundamentales trimestrales y anuales dependiendo de cada variable.

El gran desafío técnico de esta fase consistió en la incompatibilidad de los planes contables entre diferentes sectores. Para resolverlo, el algoritmo bifurcó la extracción en dos grandes arquitecturas contables:

1. **Empresas No Financieras (Corporativas e Industriales):** Evaluadas mediante la cadena de valor tradicional (EBITDA, flujo de caja libre, etc.).
2. **Empresas Financieras (Bancos y Aseguradoras):** Evaluadas mediante métricas de asunción de riesgo e intermediación. Se priorizó la extracción del Margen de Intereses, las Primas Devengadas y, críticamente, los ratios normativos de adecuación de capital (Ratio Tier 1 y Solvencia II entre otros).

La inclusión de estas variables asegura que el modelo de optimización internalice la rentabilidad financiera real y la resiliencia del balance frente a escenarios de estrés macroeconómico. Una vez que el algoritmo realiza las consultas separadas para ambos grupos contables en un año fiscal específico, ejecuta una concatenación matricial, unificando el formato y rellenando con valores nulos (`NaN`) aquellas variables que no aplican a un sector determinado. Las variables se pueden ver claramente en el cuadro 4.3.

Cuadro 4.3: Taxonomía de Variables Fundamentales Extraídas por Grupo Contable.

Categoría de Análisis	**Empresas No Financieras (Corporate)**	**Empresas Financieras (Bancos y Seguros)**
Resultados y Rentabilidad	Beneficio_Neto, ROE, Ingresos, EBITDA, EBIT, Operating_Margin.	**Comunes:** Beneficio_Neto, ROE. **Banca:** Ingresos_Intereses_Netos, Resultado_Operativo, Gastos_Operativos, Efficiency_Ratio. **Seguros:** Ingresos_Primas, Gastos_Siniestros, Combined_Ratio.
Balance, Deuda y Solvencia	Activos_Totales, Deuda_Total, Deuda_Neta, Total_Debt_To_Equity, Total_Debt_To_EBITDA.	**Comunes:** Activos_Totales, Total_Debt_To_Equity, Deuda_Total. **Banca:** Depositos_Totales, Prestamos_Netos, Ratio_Tier_1. **Seguros:** Reservas_Tecnicas, Inversiones_Totales, Solvency_Ratio.
Múltiplos de Valoración	Capitalizacion_Bursatil, P_E, Price-to-book value, Rentabilidad_Dividendo.	Capitalizacion_Bursatil, P_E, Price-to-book value, Rentabilidad_Dividendo.

Fuente: Elaboración propia.

Finalmente, tras completar el bucle temporal, el script consolida un *dataframe* histórico y realiza un *merge* con el catálogo de empresas, exportando el panel final que será inyectado junto con las series de precios temporales en el entorno de simulación del agente algorítmico.

4.2.3. Entorno Cualitativo

Finalmente, para que los modelos logren una comprensión completa del mercado bursátil, se busca capturar el componente irracional y de expectativas que mueve las cotizaciones a diario. Pese a que la evidencia de Yang et al. (2024) muestra como el sentimiento del inversor mantiene una explicabilidad marginal en los indicadores de volatilidad de los mercados durante periodos de estabilidad, para este estudio se ha considerado relevante obtener un análisis de sentimiento de las noticias extraidas.

Para integrar estos datos, se ejecutó un proceso de *web scraping* focalizado en obtener la información de *El Economista*. El sistema capturó los titulares y descripciones de las noticias publicadas para cada uno de los *tickers* del universo durante el periodo de estudio. Este corpus documental constituye la base empírica para la aplicación de

modelos de análisis de sentimiento (Gonzalez, 2020), garantizando que cada observación cualitativa esté vinculada de forma inequívoca a un activo y a un marco temporal específico. Al cuantificar el sentimiento de las noticias, el agente algorítmico asimila las expectativas del mercado como una variable numérica adicional, completando así un entorno de observación integral para la toma de decisiones.

Cuadro 4.4: Muestra de extracción de noticias (5 observaciones del dataset).

Ticker	**Fuente**	**Fecha**	**Titular (Extracto)**
ANA.MC	El Economista	Thu, 03 Jul 2025...	Acciona supera el 90 % de participación en el capital de...
ANE.MC	El Economista	Mon, 18 Aug 2025...	Las renovables europeas rebotan con una normativa fiscal más benévola...
ACX.MC	El Economista	Sat, 18 Oct 2025...	'La Cartera' vende Acerinox con un 26 % e incluye en el radar a Sabadell...
ACS.MC	El Economista	Sun, 09 Mar 2025...	Un fondo de Atl Capital es el más rentable entre los 500 productos...
AENA.MC	El Economista	Tue, 21 Oct 2025...	Citi elimina el potencial de Aena mientras la gestora española del aire...

Fuente: Elaboración propia.

4.3. Análisis Exploratorio de los Datos

En este apartado se va a desarollar el Análisis Exploratorio de Datos (EDA realizado sobre los diferentes conjuntos de datos obtenidos de los activos pertenecientes universo. Este análisis se realiza sobre los datos de distinta naturaleza y haciendo una selección cruzada para estudiar relaciones existentes entre las diferentes variables y determinar si existe información redundante entre los datasets mediante matrices de correlación.

4.3.1. Datos de cotización

La figura 8.1 del Anexo muestra un mapa de calor de disponibilidad de datos que refleja como de completos son los datos de cotización del universo. A través de una escala cromática binaria, se evidencia la presencia de información completa mediante el color purpura, mientras que los registros ausentes en las series temporales se resaltan en color amarillo. La visualización permite identificar con precisión tanto brechas temporales aleatorias como columnas de datos nulos prolongados, las cuales corresponden a casos específicos como salidas a bolsa en el caso de Acciona Energias Renovables (ANE.MC), Cirsa Corporations (CIRSA.MC), ECOENER (ECNER.MC), HBX Group International (HBX.MC) y Puig Brands (PUIGb.MC) o periodos de suspensión de cotización como fue el caso de Grupo Ezentis (EZEN.MC) debido a la solicitud de preconcurso de acreedores y reestructuración financiera (Fernández, 2022).

Observar la disponibilidad de los datos de cotización permite ver cuales pueden ser las dificultades técnicas para el posterior procesamiento. En este caso, el problema se aborda de una forma tan sencilla como imponer de forma autoritaria un valor cero a los datos NaN(los retornos de esos días tambien serán NaN) para que el agente gestor de la cartera sepa que durante los periodos con valor cero, efectivamente, no hubo cotización de esas acciones.

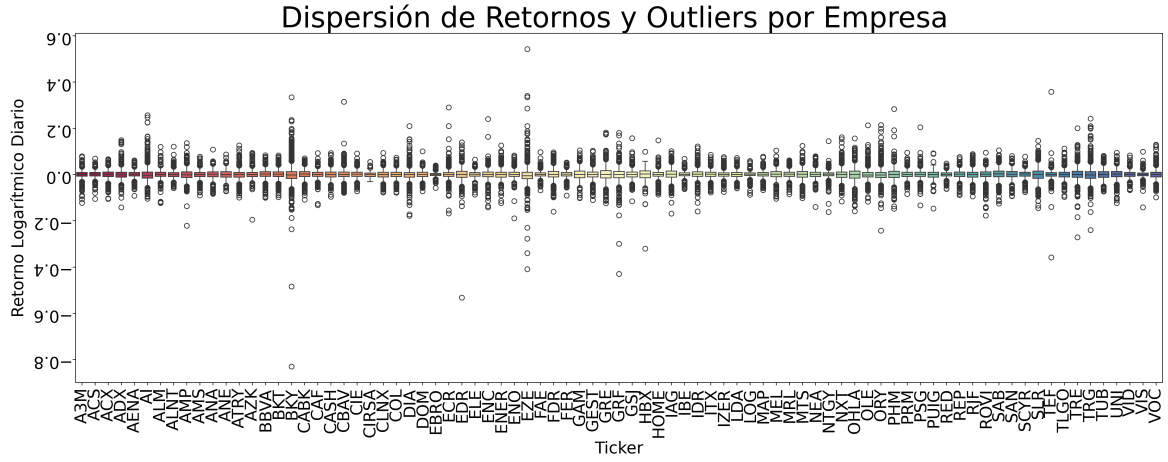


Figura 4.1: Boxplot de los retornos del universo
Fuente: Elaboración propia.

La Figura 4.1 expone la distribución y la dispersión de los retornos logarítmicos diarios de los activos del universo mediante diagramas de caja. El rasgo estadístico más evidente es la marcada compresión de los cuerpos de las cajas en torno al cero, sobre las cuales orbitan varios puntos que definen los outliers del conjunto de datos, tanto en colas superiores como inferiores. En la figura, destacan el choque negativo que roza un retorno diario de -0.8 en Berkeley Energia (BKY.MC) o la extrema dispersión y asimetría en los retornos de Grupo Ezentis (EZEN.MC), reflejo directo de sus respectivas crisis corporativas y regulatorias mencionadas con anterioridad.

Esta morfología colapsada muestra indicios de como la distribución del precio de las acciones tiene forma leptocurtica y colas pesadas, un hecho estilizado fundamental en series temporales financieras que invalida asumir una distribución normal para el cálculo del riesgo de mercado (López De Prado et al., 2025). Esta suposición se confirma de forma empirica observando la figura 8.3 del Anexo que muestran las acciones de referencia para todo el universo.

Por otra parte, la figura 4.2 examina la distribución del Max DrawDown (MDD) a lo largo del universo de activos, ordenados de mayor a menor severidad en la pérdida máxima. Esta métrica mide el peor escenario de pérdida histórica latente y la exposición al riesgo de ruina temporal. De aqui obtenemos dos observaciones clave, la asimetría del riesgo de cola y el efecto protector de la capitalización. El extremo izquierdo del gráfico

revela pérdidas catastróficas que superan el −60 % e incluso el −80 %. Destaca el Grupo Ezentis (EZEN.MC) con un drawdown cercano al −95 %, seguido de empresas como DIDA.MC y BKY.MC. Estos hundimientos estructurales representan la materialización de riesgos especificos de cada empresa.De forma paralela, se observa un patrón claro en la distribución de colores. Las empresas de pequeña capitalización (IBEX Small Cap, barras rojas) y mediana capitalización (IBEX Medium Cap, barras azules) muestran una alta concentración en la zona de drawdowns profundos (> −50 %). Por el contrario, el flanco derecho del gráfico (activos con mayor resiliencia y drawdowns contenidos entre el −15 % y −30 %) está principalmente dominado por empresas de gran capitalización del IBEX 35 (barras verdes), tales como Ferrovial (FER.MC), Logista (LOG.MC) o Viscofan (VIS.MC).

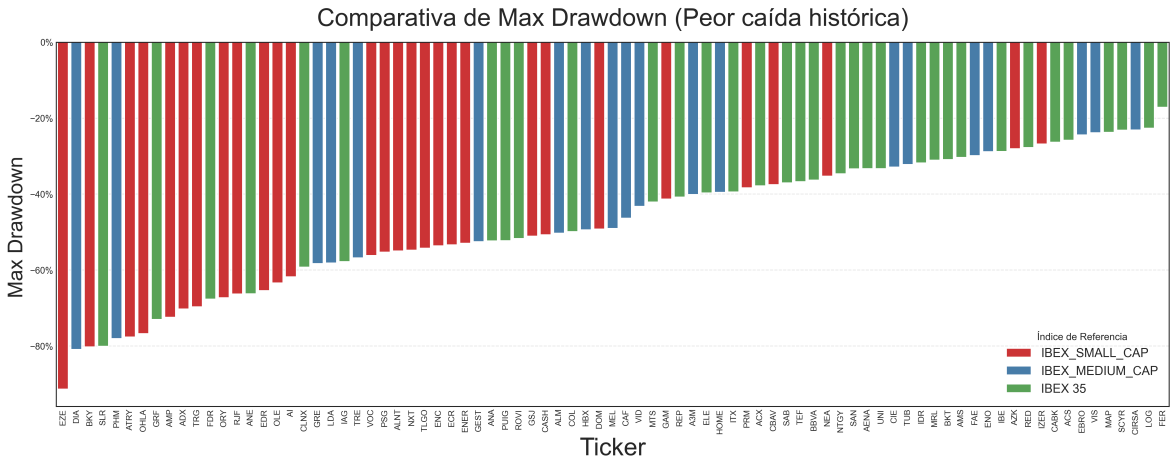


Figura 4.2: Max Drawdown de las acciones del universo
Fuente: Elaboración propia.

Por ultimo, en la figura 8.4 del Anexo se traslada el análisis al marco de la Teoría Moderna de Carteras de Markowitz, mapeando los activos en el espacio bidimensional de Volatilidad Anualizada (σ) y Rentabilidad Anualizada ($CAGR$). El gráfico incorpora la frontera eficiente (la Capital Market Line o CML), construida a partir de un activo libre de riesgo fijado en el 2 % y la cartera de tangencia óptima. Bajo estos parametros, se identifica al Banco Sabadell (SAB.MC) como el activo que ha presentado el mejor comportamiento ajustado por riesgo durante este periodo, actuando como la cartera de tangencia con un Ratio de Sharpe máximo de 1.43 La recta de la CML nace en el Risk-Free (2 %) y pivota sobre este activo, trazando la frontera de eficiencia teórica combinada. De acuerdo con el modelo CAPM de Sharpe (1964) y la hipótesis de eficiencia de mercado de Fama (1970), ningún activo individual debería batir de forma sostenida a la CML si el mercado fuera perfectamente eficiente. El mapa demuestra que la gran mayoría de las empresas se sitúan muy por debajo de la línea, dando a entender que pueden albergar un riesgo específico que no está siendo retribuido por el mercado.

4.3.2. Datos fundamentales e indicadores técnicos

Tras caracterizar las propiedades estadísticas de las series temporales de precios, el proceso de análisis se desplaza hacia un enfoque completo que unifica la estructura dinámica del mercado con la realidad contable de las empresas del universo. La inclusión simultánea de ambas vertientes analíticas responde a la necesidad de suministrar al algoritmo un entorno de información completo, capaz de capturar tanto las dinámicas de comportamiento y momentum a corto plazo como la solidez estructural y viabilidad financiera a largo plazo de los activos.

Indicadores técnicos

La matriz de correlación de Pearson mostrado en 8.5 expone de forma nítida cómo se agrupan los indicadores según su naturaleza analítica, revelando una elevada redundancia lineal en el bloque superior izquierdo e inferior derecho. Los indicadores de momento explicados en el cuadro 4.2(RSI_{14}, $Stoch_k$ y $Stoch_d$) presentan una correlación positiva muy alta (0.83 a 0.92), demostrando que capturan la misma dinámica de sobrecompra/sobreventa. A su vez, el bloque inferior derecho son los indicadores de volatilidad y tendencia con correlaciones perfectas o casi perfectas (0.99 a 1.00). Mantener todas estas variables en el espacio de estados es ineficiente, por el hecho de que introducen ruido redundante que no aportaran valor predictivo real.

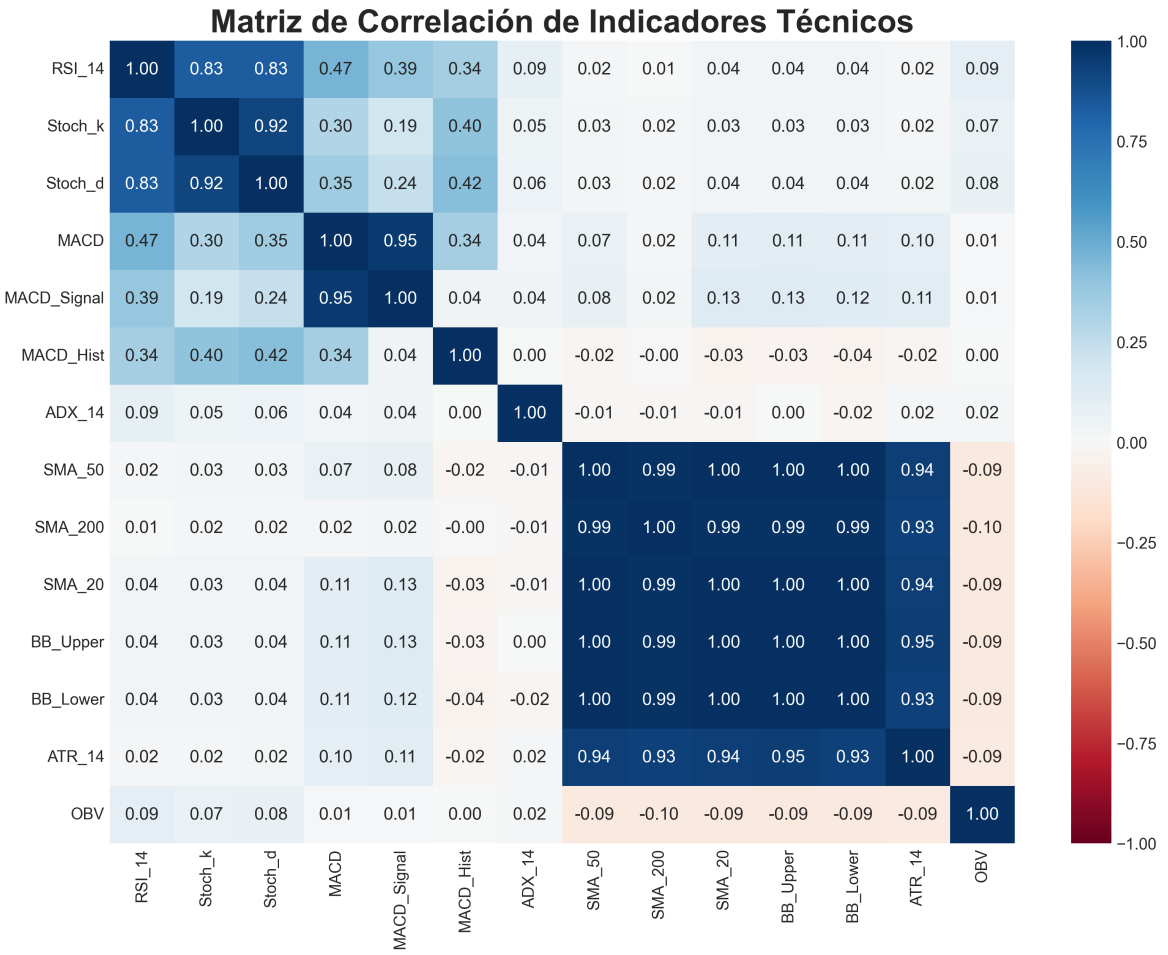


Figura 4.3: Correlaciones de los Indicadores Técnicos
Fuente: Elaboración propia.

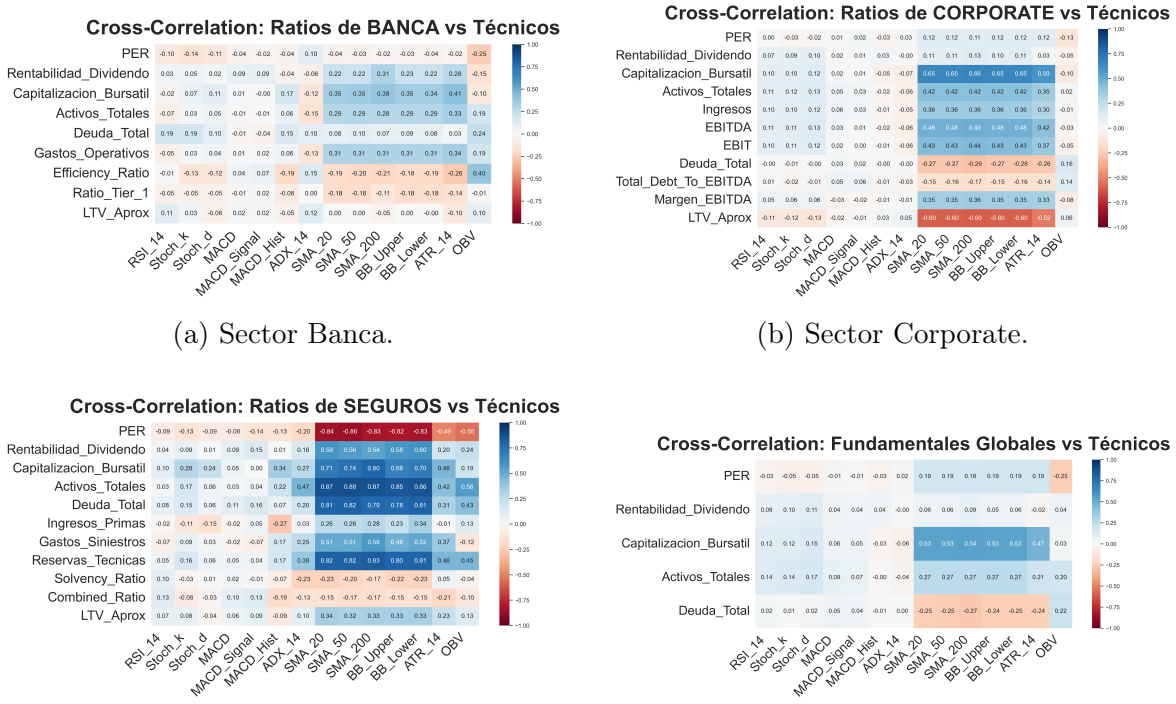
Siguiendo al estudio de las correlaciones, los histogramas de la figura 8.5 del Anexo reafirman las suposiciones de la matriz de correlación y analizan la viabilidad de los datos para ser utilizados Los indicadores calculados a partir del precio absoluto ($SMAs$, BBs) y el ATR_{14} muestran una distribución idéntica: un pico masivo cerca de cero y una cola extremadamente larga hacia la derecha. Esto puede deberse a la mezcla heterogénea del universo, donde conviven acciones que cotizan a decenas de euros con Small Caps que cotizan a céntimos. Luego, las tres métricas del MACD ($MACD$, $MACD_{Signal}$, $MACD_{Hist}$) exhiben distribuciones simétricas pero fuertemente leptocúrticas (con un pico central extremadamente agudo en cero), lo que puede denotar que la mayor parte del tiempo el mercado no registra cruces ni divergencias significativas. Por ultimo, el RSI_{14} muestra una distribución cuasi-normal perfectamente contenida en su rango teórico $(0, 100)$ y los estocásticos muestran una concentración en los extremos inferiores, reflejando distribuciones truncadas.

Indicadores fundamentales

Así como se han estudiado las variables técnicas y fundamentales, para este proyecto es relevante evaluar las relaciones de interdependencia entre los valores fundamentales, segmentados según su grupo contable. La presentación y análisis de estas matrices de correlación se realiza de manera independiente por sector debido a la misma cuestión metodológica de la obtención de datos: consolidar todo el universo en una única gráfica unificada generaría una matriz dispersa con una alta concentración de valores nulos. Esta ausencia de datos responde a la naturaleza heterogenea de cada grupo contable.

Al observar los mapas de correlación cruzada es notable observar como destacan las correlaciones existentes en el sector seguros(figura 4.4c). Estas correlaciones pueden no implicar nada a nivel macro, dado que solo hay dos empresas clasificadas como aseguradoras en el universo, que son Mapfre y Linea Directa (ver la columna industria en el cuadro 8.1), por lo que esta relación no necesariamente implica causalidad.

Por el contrario, al analizar las variables fundamentales comunes y múltiplos de valoración frente al tamaño, se observa que las correlaciones bajan significativamente, manteniéndose en un rango muy moderado entre el 0.12 y el 0.40. Variables como el PER, la Rentabilidad por Dividendo o el Margen EBITDA aportan una información mucho más independiente y no contaminada por la escala de la empresa. Esto justifica la decisión metodológica de alimentar el espacio de estados del algoritmo con variables estaticas que permitan mostrar las dos realidades de las empresas.



(a) Sector Banca.

(b) Sector Corporate.

(c) Sector Seguros.

(d) Fundamentales Comunes

Figura 4.4: Análisis de correlación cruzada entre variables fundamentales y ratios financieros, segmentado por grupo contable y agregado.
Fuente: Elaboración propia.

4.3.3. Datos Cualitativos y Procesamiento de Lenguaje Natural (NLP)

Para dotar al agente algorítmico de una visión que trascienda el precio y la contabilidad pura, se ha procesado un dataset cualitativo compuesto por 4.372 noticias y titulares financieros. El objetivo de esta fase exploratoria es diagnosticar la morfología de la información mediática y validar la capacidad del modelo de Procesamiento de Lenguaje Natural (NLP) para destilar texto en bruto en una señal numérica direccional ejecutable.

El análisis exploratorio refleja un marcado sesgo de cobertura mediática. Como se observa en la figura 4.5, la distribución confirma que el IBEX 35 y sectores estratégicos como industria, consumo cíclico y *utilities* acaparan la inmensa mayoría del flujo informativo.

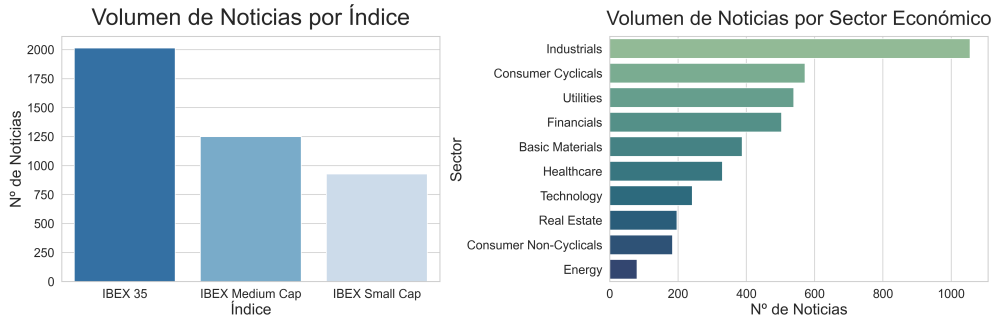


Figura 4.5: Volumen de noticias por índice bursátil y sector económico.
Fuente: Elaboración propia.

Esta polarización extrema a nivel micro se evidencia claramente en la evaluación del desequilibrio informativo por empresa (Figura 4.6). Esto significa que el modelo dispondrá de una alta densidad de señales para las *Large Caps*, pero exigirá lidiar con una drástica caída de información en los estratos inferiores. En cuanto a la morfología pura, la distribución de longitud demuestra empíricamente que el dataset no está compuesto por artículos extensos, sino por titulares y teletipos rápidos de entre 13 y 20 palabras. Esta característica resulta idónea para la arquitectura NLP, ya que minimiza el ruido semántico y facilita la extracción directa del sentimiento sin sufrir truncamientos de contexto.

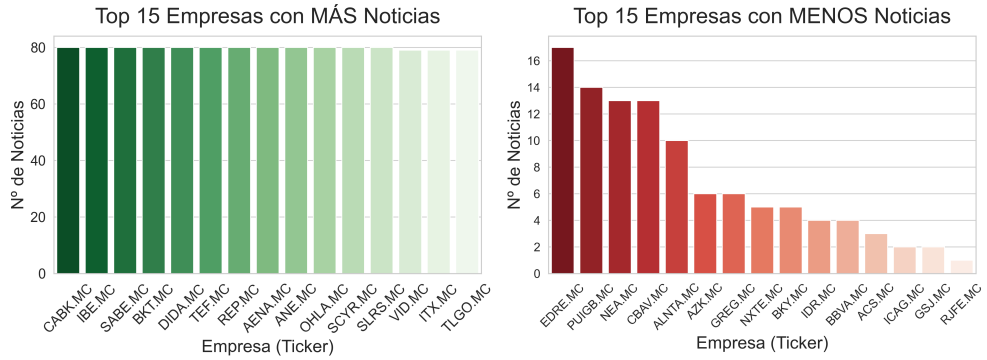


Figura 4.6: Niveles de saturación y escasez de noticias a nivel de empresa.
Fuente: Elaboración propia.

Una vez caracterizado el corpus, su evaluación mediante el modelo NLP especializado revela una distribución de polaridad altamente asimétrica, propia de los medios de comunicación corporativa. La Figura 4.7 detecta un dominio absoluto de la categoría **Neutral**, que agrupa 3.070 registros (el 70,22 % del total). Le sigue el sentimiento **Positivo** con 991 observaciones (22,67 %) y, finalmente, un bloque minoritario de 311 registros de sesgo **Negativo** (7,11 %). Esta concentración sugiere que la información mediática ha mantenido un tono predominantemente descriptivo u objetivo.

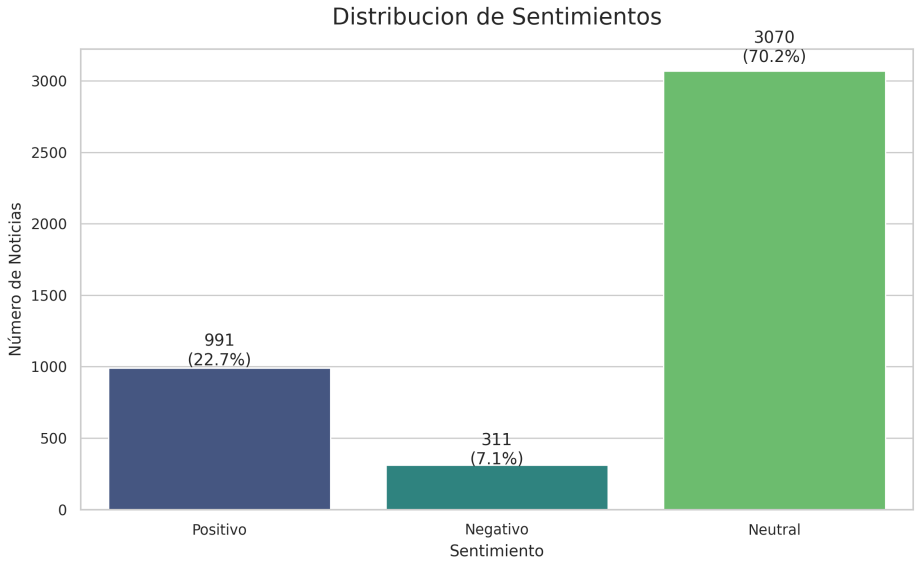
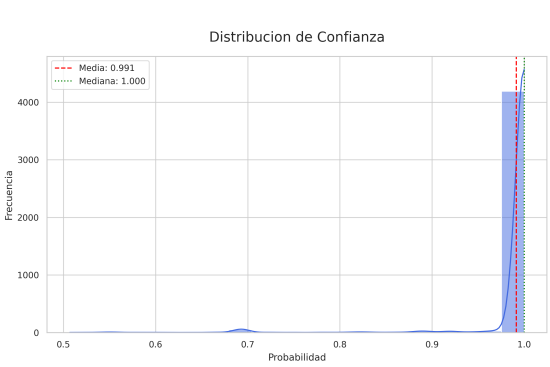
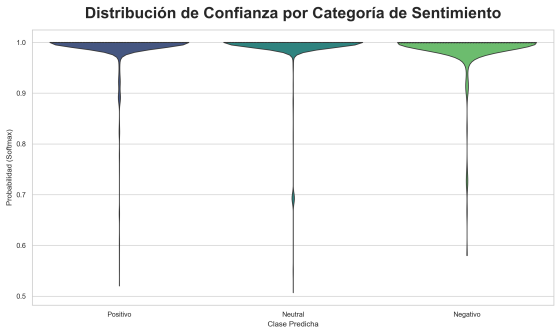


Figura 4.7: Distribución de los sentimientos detectados por el modelo de NLP.
Fuente: Elaboración propia.

Para auditar la fiabilidad de esta clasificación, se analizó el nivel de confianza emitido por la red neuronal subyacente. En la figura 4.8a el modelo demuestra un elevado grado de seguridad en sus inferencias de clasificación, registrando una media general de 0,9914 y una mediana de 0,9999. La distribución fuertemente asimétrica hacia la derecha en el histograma general. Al desglosar la homogeneidad observada en la figura 4.8b, confirman que el algoritmo discrimina las tres categorías con máxima convicción, descartando la presencia de ambigüedad sistemática.



(a) Histograma general de confianza.



(b) Distribución desagregada por sentimiento.

Figura 4.8: Evaluación de la confianza del modelo de NLP: a) Histograma general de las puntuaciones de confianza para todas las predicciones y b) Diagrama de violín sobre la distribución de la confianza desagregada por cada categoría de sentimiento.
Fuente: Elaboración propia.

Finalmente, para evaluar la utilidad predictiva del modelo, se cruzó esta métrica cualitativa con la rentabilidad anualizada de los activos mediante un *Score Polarizado*. Como ilustra la Figura 4.9, se evidencia una clara correlació positiva. Las empresas

con una opinión pública favorable tienden a generar retornos superiores, mientras que aquellas fuertemente penalizadas mediáticamente se concentran en zonas de rendimiento bajista.

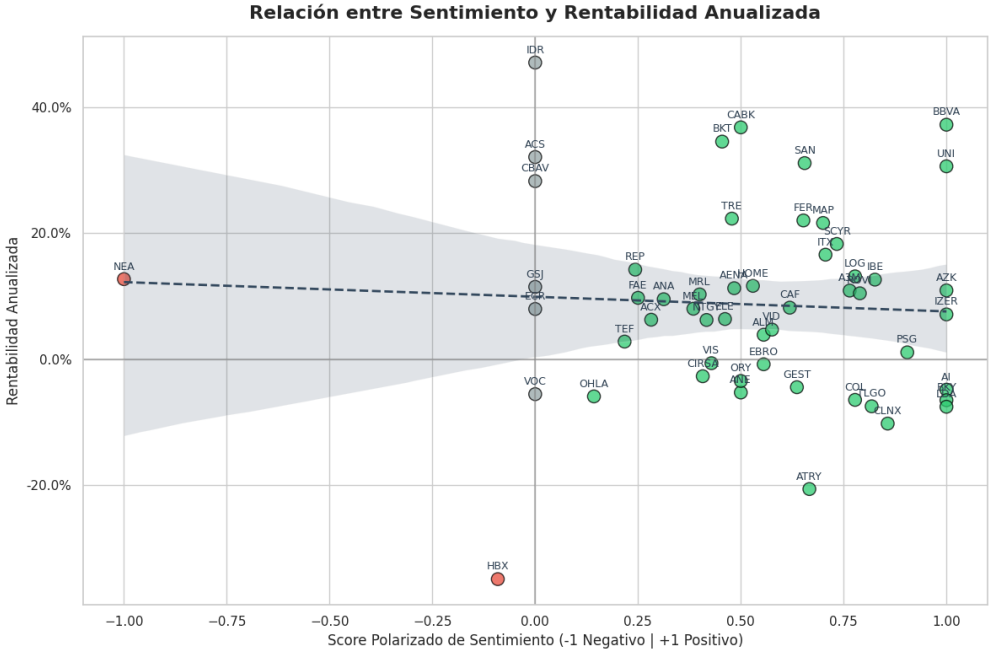


Figura 4.9: Relación entre el Score Polarizado de sentimiento y la rentabilidad anualizada.
Fuente: Elaboración propia.

4.3.4. Procesamiento final de los datos

Una vez se han obtenido los resultados númericos del procesamiento de datos cualitativos, con el objetivo de intentar optimizar la carga computacional de los modelos, se ha realizado un procesamiento final sobre el conjunto de datos. Este procesamiento se fundamenta en una reducción de características, evaluada mediante la experiencia previa de todos los experimentos realizados con anterioridad, así como en la estandarización de las variables numéricas. Para garantizar la integridad metodológica y no incurrir en (*look-ahead bias*) durante el proceso, los parámetros estadísticos de esta normalización se calibraron separando estrictamente los datos de entrenamiento y los datos de test.

La estandarización implementada corresponde al método Z-Score mediante la expresión matemática $z = \frac{x-\mu}{\sigma}$. Donde x representa el valor original de la observación financiera analizada.

El parámetro μ es la media muestral de la característica calculada únicamente en el periodo de entrenamiento.

El parámetro σ corresponde a la desviación típica muestral calculada de forma exclusiva en la fase de entrenamiento.

Tras aplicar la reducción de características definida, el espacio de estado proporcionado a los algoritmos queda conformado por las siguientes variables:

- **Indicadores Técnicos:** SMA_200, SMA_50, ATR_14, MACD_Signal, OBV y Volatilidad_Diaria.
- **Variables Fundamentales:** PER, Capitalizacion_Bursatil, Rentabilidad_Dividendo, ROE, Price-to-book value, Operating_Margin, Total_Debt_To_EBITDA, Margen_EBITDA, Ratio_Tier_1, Solvency_Ratio y Combined_Ratio.
- **Procesamiento de Lenguaje Natural (NLP):** Sentimiento_Num.

Finalmente, los datos estan completamente procesados para poder ejecutar el algoritmo genético y evaluar su viabilidad gestionando la cartera

Capítulo 5

Metodología: Algoritmo Genético

5.1. Metodología: Entorno de Simulación y Algoritmo Genético

En este apartado se describe el diseño del modelo computacional desarrollado para la optimización dinámica de carteras de inversión. La arquitectura propuesta se divide en dos componentes fundamentales: el entorno de simulación financiera, que define las reglas del mercado, y el algoritmo evolutivo, encargado de optimizar la política de inversión subyacente basada en redes neuronales [1]

5.1.1. Definición del Entorno de Simulación Financiera

El problema de gestión de carteras se formula como un Proceso de Decisión de Markov (MDP) parcialmente observable, implementado bajo el estándar de la librería *Gymnasium* mediante un entorno personalizado a las características establecidas (Towers et al., 2023). Este entorno simula un mercado bursátil diario donde un agente debe tomar decisiones de rebalanceo de pesos atendiendo a costes de transacción y limites de cardinalidad.

Espacio de Estados (Observaciones)

En cada instante temporal t, el entorno proporciona una representación del estado del mercado $\mathcal{S}_t$. El vector de observación incluye variables técnicas y financieras normalizadas de los activos del universo de estudio. Estas incluyen series temporales de precios de cierre, métricas de volatilidad y la composición actual de la cartera, permitiendo al agente inferir patrones de momentum temporal y reversión a la media.

[1] Con el fin de garantizar la reproducibilidad, el código completo del entorno y el Algoritmo Genético estan alojados en el repositorio indicado en el Anexo 8.1.

Espacio de Acción y Mapeo Fenotípico

El agente emite un vector de acciones continuas en $\mathbb{R}^A$, donde A es el número total de activos negociables. Para garantizar la viabilidad financiera de las decisiones, el entorno aplica una función de activación escalar *Softmax* sobre el vector de salida a. Los pesos asignados a cada activo w_i se definen como:

$$w_i = \frac{e^{a_i - \text{máx}(a)}}{\sum_{j=1}^{A} e^{a_j - \text{máx}(a)}} \tag{5.1}$$

Esta transformación proyecta las decisiones puras de la red neuronal hacia un espacio fenotípico de ponderaciones de cartera estrictamente válido, donde cualquier fracción del capital no asignada explícitamente se mantiene en liquidez (Cash).

Función de Recompensa del Entorno

En la arquitectura de este estudio se implementa un desacoplamiento metodológico intencionado entre la función de recompensa diaria del entorno y la función de *fitness* global del algoritmo evolutivo, resolviendo así la incompatibilidad matemática de medir el riesgo a muy corto plazo. Mientras que el algoritmo genético (*RealCodedGA*) opera en una capa de abstracción superior utilizando el ratio de Sharpe del episodio completo para evaluar la consistencia y supervivencia de los cromosomas, la función *step()* del entorno requiere una señal densa, diaria y determinista. Al calcular el diferencial de retornos logarítmicos en cada paso, el entorno se limita a actuar como un árbitro contable del mercado que mide el *Alpha* inmediato y aprovecha la propiedad de aditividad temporal de estos retornos, evitando introducir el ruido masivo y la inestabilidad que provocaría intentar aproximar la volatilidad en horizontes diarios.

Por consiguiente, la recompensa en el instante t, denotada como R_t, se define como el diferencial de los retornos logarítmicos diarios entre la cartera gestionada (V) y el índice bursátil de referencia IBEX 35 (I):

$$R_t = \ln\left(\frac{V_{p,t}}{V_{p,t-1}}\right) - \ln\left(\frac{I_t}{I_{t-1}}\right) \tag{5.2}$$

A efectos prácticos del motor de optimización, esta recompensa local es ignorada por el algoritmo genético durante el entrenamiento, pero cumple dos funciones fundamentales. Por un lado, dota al entorno de la estructura técnica estándar exigida por la librería *Gym*, garantizando la compatibilidad nativa del simulador en la ejecución de cada paso . Por otro lado, este registro paso a paso hereda la utilidad de experimentos previos del desarrollo, donde fue empleado para monitorizar y analizar el comportamiento dinámico del modelo

5.1.2. Algoritmo Genético

La estrategia de asignación de activos y la política de rebalanceo dinámico de la cartera en cada instante t se definen formalmente bajo el marco de la computación evolutiva propuesta por Michalewicz (1996) y Chang et al. (2000). En lugar de recurrir al cálculo numérico de gradientes en tiempo real, se parametriza la conducta del agente mediante un Perceptrón Multicapa determinista. Esta red actúa como el cerebro que procesa un vector de observaciones de dimensión O (todas las características incluidas al algoritmo) a través de una capa oculta de 8 neuronas, emitiendo en su capa de salida un vector de dimensión A que dicta las órdenes de compra, venta o mantenimiento de ponderaciones para cada activo del mercado. Bajo este enfoque, el genoma o cromosoma del algoritmo no es una cadena binaria artificial, sino la codificación lineal y continua de todos los pesos sinápticos y sesgos de la red, cuya dimensión total D representa la complejidad de la estrategia comercial:

$$D = (O \times 8) + 8 + (8 \times A) + A \tag{5.3}$$

El proceso de optimización no busca adivinar precios de cierre estáticos, sino descubrir reglas conductuales complejas evaluando el desempeño del agente sobre horizontes temporales completos de inversión. Para guiar este aprendizaje, cada configuración de red $\theta_i \in \mathbb{R}^D$ dentro de una población competitiva es sometida a un estudio de rendimiento mediante una función de aptitud (*fitness*) escalar (S). Se han elaborado varios experimentos utilizando diferentes configuraciones de la función de fitness del algoritmo genético con la intención de ver los diferentes resultados que se obtienen. Al final, se decide utilizar el ratio de Sharpe como el optimizador del algoritmo para simplificar el estudio a una unica variable con la que se pueda determinar una explicación sobre las variaciones de las ponderaciones de la cartera.

$$S(\theta) = \frac{\bar{R}_p - R_f}{\sigma_p} \tag{5.4}$$

Siendo la tasa libre de riesgo el $R_f = 2\,\%$

5.1.3. Parámetros del modelo

Para finalizar, en base a la realización de experimentos previos utilizando optimizaciones bayesianas mediante el paquete `Optuna` (Akiba et al., 2019), se ha determinado que las mejores soluciones del algoritmo genético se obtienen utilizando los hiperparámetros técnicos referenciados en el trabajo de Chang et al. (2000) y son los que se encuentran en la tabla 5.1, junto con los que determinan la politica a aplicar y las normas del entorno financiero.

Cuadro 5.1: Hiperparámetros técnicos del Algoritmo Genético y Red Neuronal

Componente	**Hiperparámetro**	**Valor / Configuración**
Algoritmo Genético	Tamaño de la población (*ga_population*)	100
	Generaciones máximas (*ga_generations*)	500
	Tamaño del elitismo (*ga_elite_size*)	2
	Tamaño del torneo (*ga_tournament_size*)	3
	Cruce BLX-α (*ga_crossover_alpha*)	0.4
	Probabilidad de mutación (*ga_mutation_prob*)	0.02 (2 %)
	Desviación de mutación (*ga_mutation_sigma*)	0.05
Política (MLP)	Capas ocultas (*hidden_dim*)	[8]
	Dimensión de la entrada (*OBS_DIM*)	12.886
	Dimensión de la salida (*ACTION_DIM*)	81
	Número total de parámetros (Genes)	103.825
Entorno Financiero	Ventana histórica (*window_size*)	10 días
	Frecuencia de rebalanceo (*rebalance_freq*)	20 días (Mensual)
	Cardinalidad máxima (*max_positions*)	10 activos
	Recorte de observaciones (*obs_clip*)	5.0
	Observaciones minimas para entrenamiento	120
	Observaciones minimas para backtest	60

Fuente: Elaboración propia.

Capítulo 6

Resultados y Análisis del Algoritmo

Tras el desarrollo de todos los apartados anteriores, se ha procedido a obtener los resultados del Algoritmo Genético bajo la optimización de la variable Sharpe, libre del sesgo de optimismo analítico. El estudio se despliega de forma incremental durante el periodo de backtest 2024-2025 a través de tres fases complementarias: en primer lugar, se valida la toma de decisiones utilizando la metodología de Inteligencia Artificial Explicable (XAI) mediante un modelo sustituto de Random Forest; en segundo lugar, se realiza un profundo estudio de sensibilidad eliminando por completo los datos fundamentales del dataset para evaluar el comportamiento del agente operando exclusivamente con indicadores técnicos; y finalmente, se disecciona la consistencia del modelo mediante el contraste de sus métricas de riesgo-rendimiento frente al índice de referencia, comprobando su capacidad de generalización internacional mediante una prueba de transferencia directa sobre los activos del índice estadounidense S&P 500.

6.1. Modelo Base: Algoritmo Genético

6.1.1. Rendimiento del modelo

El algoritmo base es el especificado con las ecuaciones 5.2 y 5.4. Para garantizar la validez de este, la figura 6.1 ilustra la trayectoria del proceso de optimización a lo largo de las generaciones, monitorizando la evolución de la función de aptitud/fitness tanto para el mejor individuo de la población como para el promedio de la solución colectiva durante todo el periodo de entrenamiento.

En las primeras generaciones se observa una pendiente marcadamente ascendente, lo que denota una fase de exploración intensa donde el operador de cruce y las mutaciones logran descubrir de forma rápida combinaciones de pesos con un elevado valor predictivo. A medida que avanzan las generaciones, la curva del mejor individuo comienza a estabilizarse, indicando que el algoritmo ha transitado hacia una fase de explotación fina, refinando los parámetros en torno a un óptimo local. Por su parte, la

aproximación gradual del rendimiento medio de la población hacia el límite superior sugiere una ligera reducción de la varianza interna y un aumento de la homogeneidad del grupo, demostrando que las reglas de asignación eficientes se propagaron de manera correcta por selección natural sin incurrir en un estancamiento prematuro.

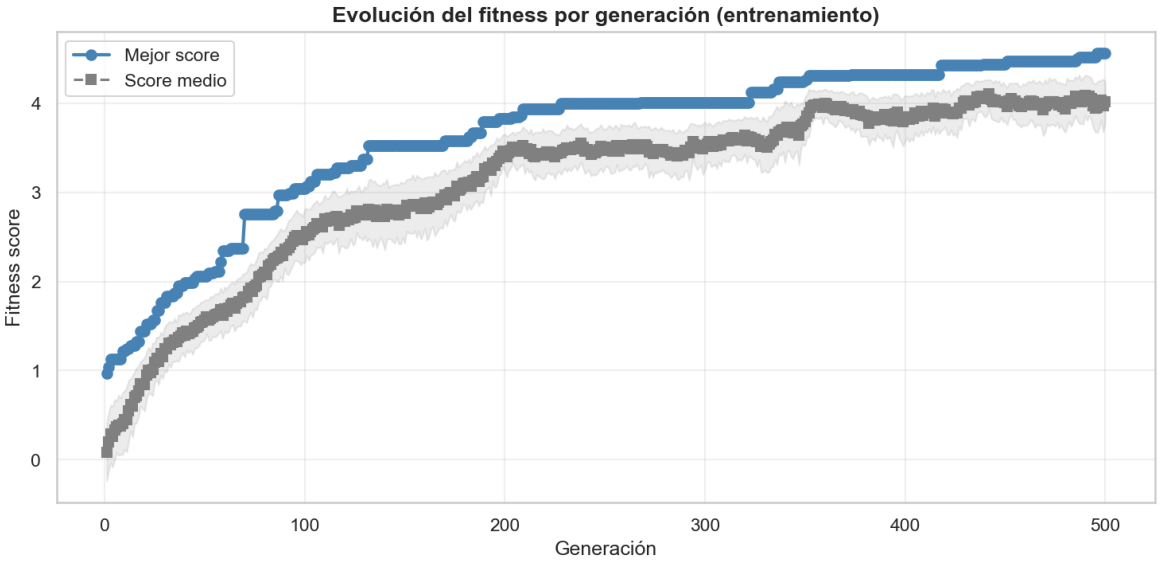


Figura 6.1: Evolución del fitness a lo largo de las generaciones
Fuente: Elaboración propia.

6.1.2. Rendimiento en el entorno financiero

Estudiando la realidad financiera del backtest, en la figura 6.2 se observa una clara divergencia en las trayectorias de acumulación de riqueza bajo un mismo punto de partida. Mientras que el índice de referencia experimenta un régimen marcadamente alcista y sostenido a lo largo del periodo, la cartera del agente evolutivo exhibe un comportamiento mucho más errático y lateral. Aunque el algoritmo logra esquivar la ruina total y culmina el periodo con un beneficio absoluto, se observa como su política de inversión es incapaz de capturar la tendencia del mercado.

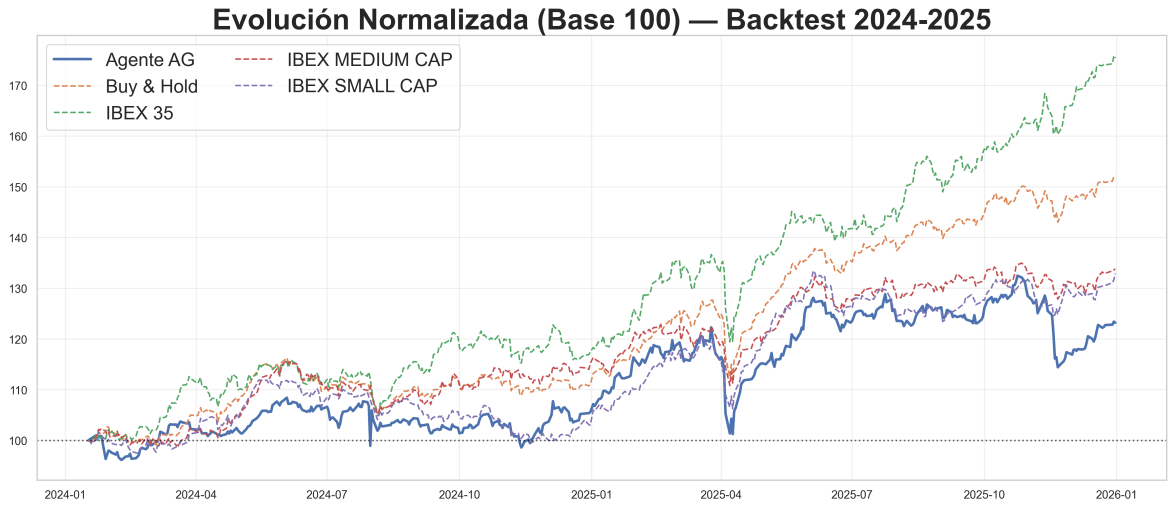


Figura 6.2: Evolución de la curva de capital: Algoritmo Genético frente a la estrategia Buy & Hold y resto de índices en 2024-2025.
Fuente: Elaboración propia.

Para cuantificar con exactitud esta divergencia, el cuadro 6.1 desglosa las métricas de rentabilidad y riesgo ajustado al cierre del periodo. Los datos empíricos del cuadro confirman el rendimiento subóptimo del modelo respecto al índice de referencia. El Algoritmo Genético optimizado por Sharpe muestra un déficit de captura de *Alpha*, generando un retorno anualizado del 11.27 % frente al 24.33 % conseguido por la estrategia *Buy and Hold* equiponderado del IBEX 35. A pesar de la mejora respecto a iteraciones previas, la asunción de riesgos sigue siendo ineficiente, operando con una volatilidad anualizada superior a la del mercado (16.21 % frente a 11.38 %).

Esta diferencia penaliza de forma clara las métricas de rendimiento ajustado por riesgo. El Ratio Sharpe, para un tipo de interés libre de riesgo del 2 % del agente se sitúa en 0.61, lo que indica que el modelo genera menos rentabilidad por cada unidad de riesgo asumida si lo comparamos con la notable eficiencia del 1.77 mostrada por la referencia en este periodo. Paralelamente, el riesgo de cola se refleja en el Máximo Drawdown, donde la cartera del agente llega a registrar una pérdida total del -17.20 %, una caída más profunda que la sufrida por la inversión pasiva, que se limitó al -12.19 %.

Este comportamiento estructural indica que el algoritmo, al concentrarse únicamente en la optimización del Ratio Sharpe, tiende a ajustar sus pesos de forma excesivamente reactiva al ruido a corto plazo. Como resultado, aunque logra controlar la volatilidad total, la política desarrollada rompe la acumulación del capital inicial e impide que la red neuronal mantenga posiciones estables en aquellos activos que presentan las tendencias alcistas estructurales más fuertes del mercado.

Cuadro 6.1: Métricas de rendimiento en backtest: AG vs Buy & Hold

Métrica Financiera	**Agente GA**	**Buy & Hold (IBEX 35)**
Retorno Total Acumulado	23,21 %	53,07 %
Retorno Anualizado (CAGR)	11,27 %	24,33 %
Volatilidad Anualizada (σ)	16,21 %	11,38 %
Ratio Sharpe	0,609	1,77
Max Drawdown (MDD)	-17,20 %	-12,19 %
Tasa de Acierto (*Win Rate*)	57,20 %	60,60 %
Valor Final de la Cartera	122.930,43 €	153.073,02 €

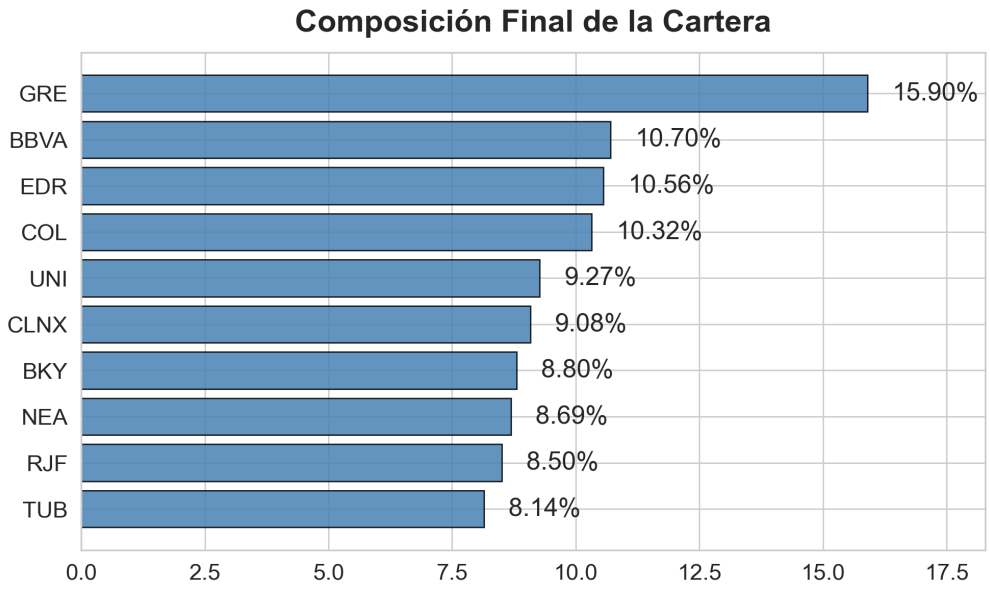
Fuente: Elaboración propia.

6.1.3. Estructura Interna: Asignación y Correlación de Activos

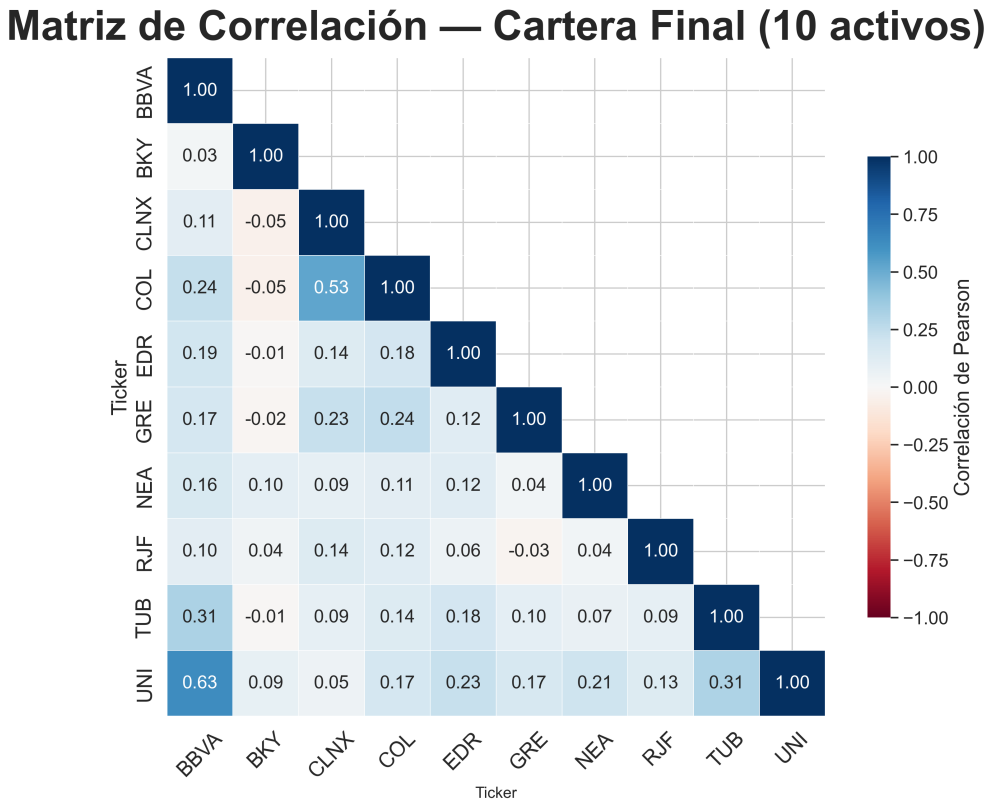
Para entender mejor el comportamiento del riesgo y cómo termina estructurada la cartera al cierre del periodo, es necesario analizar su dinámica interna. La figura 6.3 muestra dos aspectos clave: la distribución de los pesos finales que ha asignado el algoritmo (figura 6.3a) y la matriz de correlación entre esos mismos activos (figura 6.3b).

Al fijarnos en la Figura 6.3a, se observa cómo en la última rotación del backtest el algoritmo decide quedarse únicamente con 10 activos. Al final del periodo, el mayor peso se lo lleva Grenergy con un 15.90 % del capital, mientras que el resto del capital se reparte de forma bastante equilibrada en bloques que van del 8 % al 11 %. La figura propone que la red busca diluir el riesgo específico diversificando más sus posiciones.

El sentido de esta distribución se entiende mucho mejor al mirar la matriz de correlación (Figura 6.3b). El gráfico revela que el algoritmo ha elegido una cesta de acciones muy descorrelacionadas entre sí, con casi todos los coeficientes en un nivel bajo, por debajo de 0.25, e incluso con relaciones cercanas a cero o ligeramente negativas (como pasa con BKY frente al resto). Las únicas excepciones claras se deben a que pertenecen al mismo sector, como la correlación entre los bancos (UNI y BBVA con un 0.63) o las empresas de infraestructuras e inmobiliario (COL y CLNX con un 0.53). En resumen,ambas figuras sugieren cómo optimizar por la variable Sharpe obliga al modelo a evitar activos que se muevan igual al mismo tiempo, por lo que busca construir de forma natural una cartera mucho más defendida frente a la volatilidad del mercado.



(a) Composición final de la cartera.



(b) Matriz de correlación interna.

Figura 6.3: Análisis de la cartera del AG: a) Distribución porcentual de los activos seleccionados al final del periodo y b) Matriz de correlación lineal de Pearson entre los activos.

Fuente: Elaboración propia.

Por ultimo, para profundizar en la dinámica analítica de la estrategia, la figura 8.9 del Anexo muestra un mapa de calor de la composición histórica de la cartera. De

un universo elegible inicial, el agente ha decidido operar un bloque de 37 empresas, dejando al resto de compañías sin ponderación alguna durante todo el periodo. Lo relevante de esta distribución no es la exclusión de activos, sino justo lo contrario, como el algoritmo explota la capacidad de exploración del modelo mediante el mantenimiento de posiciones marginales activas. En lugar de restringir su aprendizaje a concentrar el capital únicamente en las métricas óptimas aisladas, el algoritmo genético aprovecha la flexibilidad de la red para mantener presencia en una amplia variedad de acciones, adaptando dinámicamente sus pesos ante lo que interpreta como señales de compra y venta.

6.2. Estudio de Sensibilidad: Impacto de las Variables Estáticas vs. Dinámicas

Tras consolidar y evaluar los resultados de la optimización del Algoritmo Genético con un universo de datos completo, se procede a evaluar como se comporta el modelo entrenandolo unicamente con los indicadores técnicos *ceteris paribus*. El objetivo es analizar cómo cambia el comportamiento del modelo cuando combina variables estáticas con variables dinámicas frente a un entorno restringido donde el agente opera exclusivamente con información dinámica. Al capar estas variables estáticas, se obliga al agente a tomar decisiones de asignación de pesos basándose única y exclusivamente en señales técnicas e impulsos del precio a corto y medio plazo. Este contraste permite comprobar si la inclusión de la taxonomía contable aporta un valor real a la hora de capturar tendencias alcistas y mitigar el riesgo de cola, o si, por el contrario, el modelo es capaz de generar una estrategia eficiente apoyándose solo en la dinámica del precio.

6.2.1. Rendimiento en el entorno financiero

Al analizar las métricas obtenidas del este análisis de sensibilidad, en el cuadro 6.2 se muestra el impacto estructural que supone eliminar la información contable. El agente puramente dinámico sufre una degradación en su capacidad para gestionar las caidas, evidenciada por un desplome del Máx Drawdown hasta el $-23.67\,\%$ y un repunte de la volatilidad anualizada al $17.89\,\%$. Esta hiperreactividad ante el ruido de mercado a corto plazo no solo recorta la rentabilidad anual (que cae al $9.35\,\%$), sino que penaliza claramente la eficiencia global de la cartera, arrastrando el Ratio Sharpe de 0.61 a 0.51. Sumado a la caída en la tasa de acierto (del $57.20\,\%$ al $53.80\,\%$), los datos confirman que operar basándose exclusivamente en indicadores técnicos y de precio genera decisiones de asignación mucho más erráticas e inestables.

Cuadro 6.2: Comparativa de Sensibilidad: Modelo Base vs. Modelo Dinámico

Métrica Financiera	**Modelo Base**	**Modelo Dinámico**
Retorno Total Acumulado	23,21 %	19,10 %
Retorno Anualizado (CAGR)	11,27 %	9,35 %
Volatilidad Anualizada (σ)	16,21 %	17,89 %
Ratio Sharpe	0,61	0,51
Max Drawdown (MDD)	-17,20 %	-23,67 %
Tasa de Acierto (*Win Rate*)	57,20 %	53,80 %

Fuente: Elaboración propia.

Los rendimientos acumulados de ambos modelos se ven reflejados en la figura 6.4. La curva de capital ilustra la degradación del modelo utilizado unicamente con datos técnicos. Aunque el modelo dinámico (curva roja) exhibe inicialmente un rápido crecimiento al perseguir el *momentum* del precio, a inicios de 2025 las curvas de ambos modelos cruzan, y posteriormente pierde la rentabilidad ganada durante el primer año, hasta llegar al *drawdown* del $-23,67\,\%$. Por el contrario, la trayectoria del modelo base (curva azul) demuestra su estructura defensiva ante correciones de mercado, evitando entrar en pérdidas y asegurando una senda de recuperación sostenida.

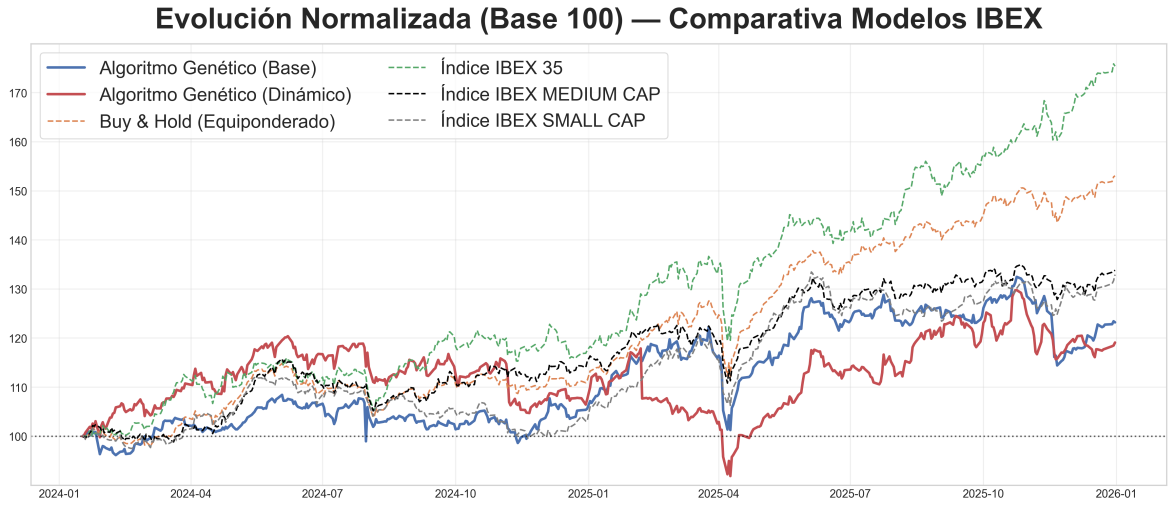
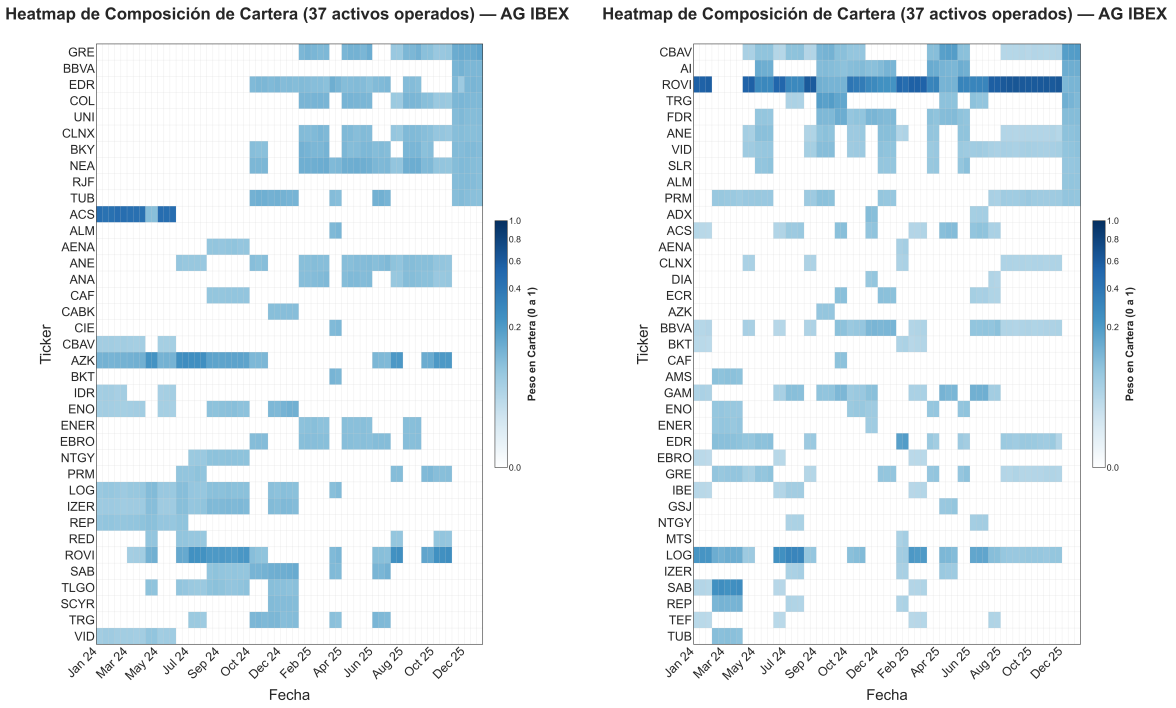


Figura 6.4: Comparativa de los modelos aplicado al IBEX
Fuente: Elaboración propia.

Asimismo, es interesante poder evaluar cual ha sido el cambio en el comportamiento del modelo para hacer esos cambios en las metricas financieras, por lo que tambien se procede a evaluar visualmente el impacto de la inclusión de los datos fundamentales. La figura 6.5 contrasta de forma directa el mapa de calor de las ponderaciones históricas del modelo base frente al modelo técnico.

La comparación directa entre ambas arquitecturas revela un cambio radical en la forma de razonamiento del algoritmo gestor. Mientras que en la figura 6.5a se consolida un patrón de bandas horizontales continuas con tonalidades tenues y persistentes, lo que demuestra que el uso de ratios contables actúa como un estabilizador de las posiciones a medio plazo y evita cierres absolutos para mitigar costes transaccionales, la figura 6.5b refleja una estructura erratica. La alternancia violenta entre bloques de alta concentración oscura y zonas en blanco puro en el modelo dinámico muestran que, al depender exclusivamente de la acción del precio a corto plazo, el agente se vuelve puramente reactivo; entra y sale del mercado de forma intermitente ante señales técnicas, lo que dispara la tasa de rotación y explica el incremento de la volatilidad y el drawdown observados en el cuadro 6.2.



(a) Modelo Base (b) Modelo Dinámico

Figura 6.5: Evolución temporal de la composición de la cartera. a) Modelo Base, y b) Modelo Dinámico
Fuente: Elaboración propia.

6.3. Modelo sustituto: Random Forest

Tal como se ha explicado en la sección 3.2, para poder explicar cuales son los fundamentos o politicas que determinan la ponderación de los activos del universo en la cartera, se utiliza la metodologia Explanaible AI. Metodológicamente, se entrena un regresor *Random Forest* para actuar como un algoritmo validador del algoritmo genético, por lo que este modelo no intenta predecir los retornos del mercado, sino replicar las ponderaciones de cartera generadas por el AG utilizando el mismo conjunto

de variables de entrada.

En el cuadro 6.3 se encuentran los hiperparámetros utilizados para el *Random Forest*, y estos responden a la necesidad de garantizar un equilibrio entre la fidelidad de la clonación y la capacidad de generalización del modelo sustituto, evitando el sobreajuste del conjunto de entrenamiento.

Cuadro 6.3: Hiperparámetros del Modelo Sustituto

Hiperparámetro	**Valor Asignado**
Número de Árboles (`n_estimators`)	200
Profundidad Máxima (`max_depth`)	10
Muestras Mínimas por Hoja (`min_samples_leaf`)	5
Folds de Validación Cruzada (`cv_n_folds`)	5

Fuente: Elaboración propia.

6.3.1. Métricas de validación

Los resultados del cuadro 6.4 revelan un contraste metodológico muy interesante sobre la capacidad de clonación del modelo sustituto. El *Random Forest* entrenado para la estrategia puramente dinámica alcanza una fidelidad elevada, registrando un R^2 en la muestra de un $0,9339$ y en validación cruzada de $0,8965$, al igual que un (*RMSE* de $0,0172$). Por su parte, el modelo base presenta métricas de ajuste más moderadas pero igualmente robustas, con un R^2 de $0,7199$ y$0,6911$. Esta divergencia no implica una deficiencia en el modelo base, sino que responde directamente a la dimensionalidad del problema. Mientras que el modelo técnico opera en un espacio simplificado de solo 8 variables de precio muy correlacionadas entre sí, el modelo híbrido duplica las características hasta las 16 variables, entrelazando dinámicas fundamentales de balance con señales técnicas. Esta mayor riqueza informativa eleva la complejidad estructural de la política del Algoritmo Genético, justificando que su aproximación sustituta sea más compleja de parametrizar, pero validando firmemente a ambos modelos para la posterior extracción de los valores SHAP.

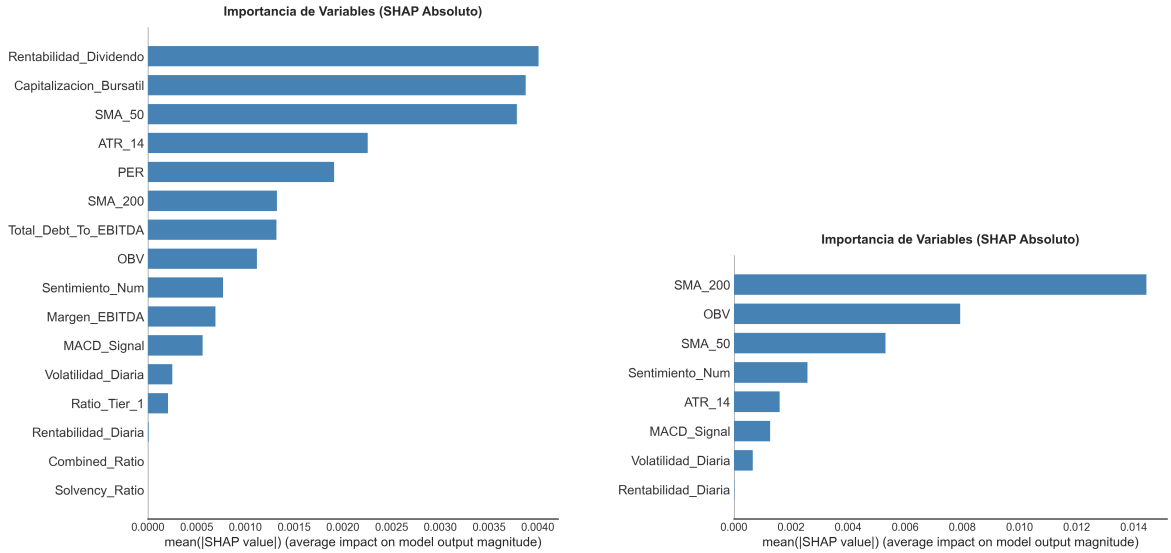
Cuadro 6.4: Métricas de Bondad de Ajuste del Modelo Sustituto

Métrica de Ajuste	**Modelo Base**	**Modelo Dinámico**
Ajuste en Muestra (In-Sample)		
R^2 In-Sample	0,7199	0,9339
RMSE In-Sample	0,0207	0,0138
MSE In-Sample	0,0004	0,0002
Validación Cruzada		
R^2 CV (Media $\pm$ Std)	$0,6911 \pm 0,0256$	$0,8965 \pm 0,0075$
RMSE CV (Media)	0,0217	0,0172
MSE CV (Media)	0,0005	0,0003

Fuente: Elaboración propia.

6.3.2. Explicabilidad de Shap

El análisis de atribución de impacto revela de forma nítida por qué ambos modelos operan con psicologías tan opuestas. En la figura 6.6a, el *Random Forest* ignora prácticamente los indicadores de precio para estructurar su convicción: las cuatro variables más determinantes son fundamentales estructurales, lideradas por el ratio de apalancamiento (*Total Debt to EBITDA*) con un impacto medio SHAP superior a 0.035, seguido por la rentabilidad por dividendo (*Dividend Yield*) y múltiplos de valoración clave como el *EV to EBITDA* y el *Price to Book Value*. Por el contrario, al eliminar las variables contables, el arbol se ve obligado a reconfigurar por completo su lógica. Los valores de SHAP se desplazan directamente hacia indicadores dinámicos de tendencia e impulso de corto plazo, donde la media móvil simple de 20 periodos (*SMA_20*) pasa a controlar todo el sesgo del modelo con un valor SHAP que duplica al resto de características, secundado por osciladores reactivos como el *RSI*. Esta radiografía de XAI confirma que el modelo base utiliza los fundamentales para mantener posiciones estables de valor, mientras que el modelo técnico cae en una dependencia absoluta de la inercia del precio, explicando matemáticamente su comportamiento errático e intermitente en el mercado.



(a) Modelo Base (b) Modelo Dinámico

Figura 6.6: Explicabilidad de Shap para. a) Modelo Base, y b) Modelo Dinámico
Fuente: Elaboración propia.

6.4. Prueba de Generalización Cruzada en el S&P 500

Para determinar si el modelo realmente ha aprendido las dinámicas del mercado con los datos entrenados, se debe hacer una prueba de generalización con datos de otro mercado para comprobar el comportamiento tomado por el algoritmo entrenado, y se evalúa su desempeño sobre un universo de inversión no visto previamente: una selección aleatoria de empresas del índice estadounidense S&P 500 (ver cuadro 8.2).

Cuadro 6.5: Resultados de la Prueba de Generalización Cruzada en el S&P 500

Métrica Financiera	**Modelo Base**	**Modelo Dinámico**	**S&P 500**
Rentabilidad Total Acumulada	3,97 %	-4,94 %	43,18 %
Rentabilidad Anualizada (CAGR)	2,01 %	-2,56 %	20,19 %
Volatilidad Anualizada (σ)	23,35 %	24,39 %	16,07 %
Ratio Sharpe	0,143	-0,041	1,142
Máximo Drawdown (MDD)	-28,49 %	-38,17 %	-18,90 %
Tasa de Acierto (*Win Rate*)	50,10 %	48,27 %	57,43 %

Fuente: Elaboración propia.

Al observar la Figura 6.7, los resultados de la prueba de generalización revelan el impacto de transferir el algoritmo a un mercado con una estructura opuesta a la de origen. Mientras el S&P 500 y su *Buy & Hold* marcan una tendencia alcista impulsada por el factor *Growth* (con un retorno del 43,18 %), los agentes genéticos no logran capturar este *momentum*. El Modelo Base, anclado por las variables fundamentales,

adopta una postura defensiva en torno a la Base 100; al interpretar los altos múltiplos estadounidenses como riesgo estructural, restringe su exposición para proteger el capital, logrando un beneficio marginal del 3,97 % pero perdiendo el coste de oportunidad del mercado alcista. Por el contrario, el Modelo Dinámico evidencia un fallo de generalización absoluto al operar sin ratios contables: su dependencia exclusiva de indicadores técnicos e impulsos de precio (diseñados para el entorno del IBEX 35) se traduce en una hiperreactividad destructiva ante la volatilidad americana que hunde sistemáticamente su curva de capital por debajo del nivel inicial.

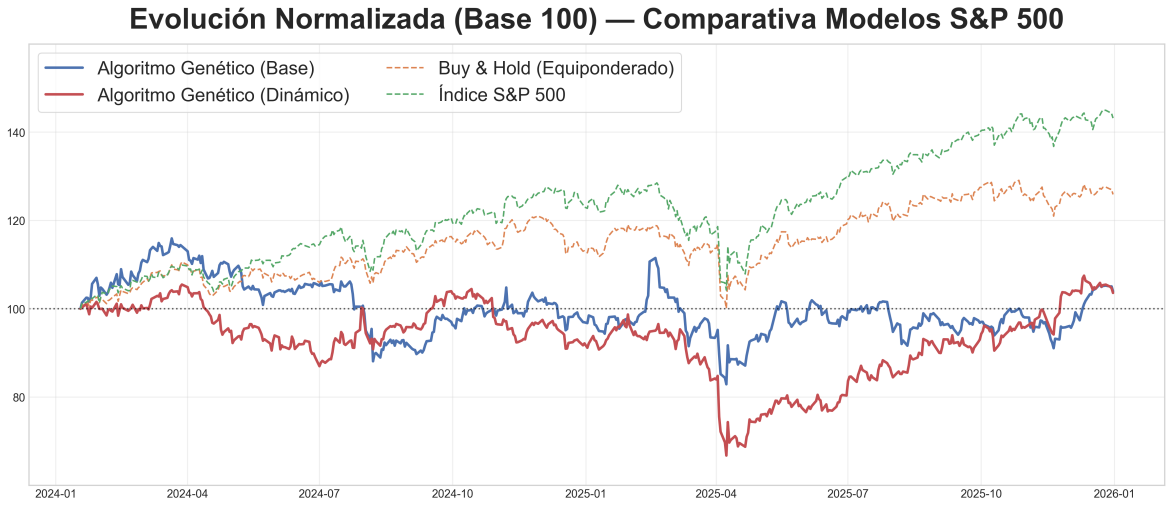
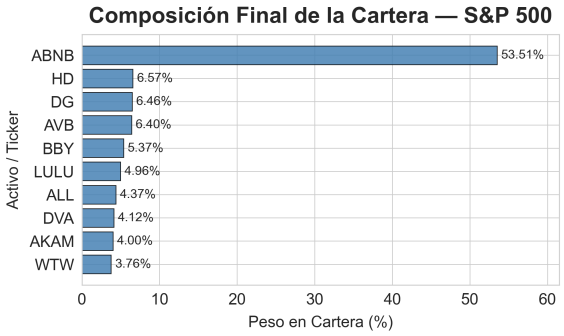


Figura 6.7: Generalización de los modelos al S&P 500
Fuente: Elaboración propia.

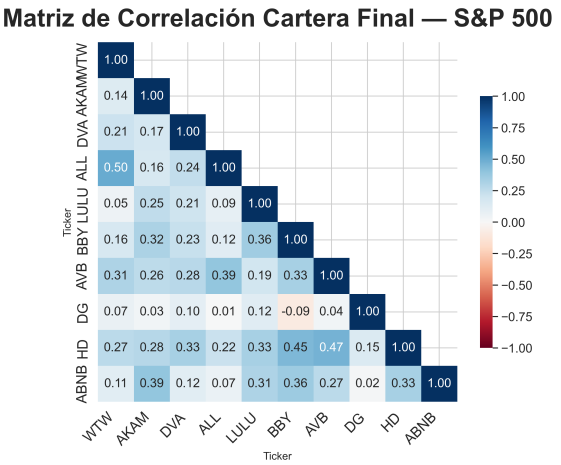
Siguiendo el análisis, la figura 6.8 muestra el análisis estructural al cierre del periodo. Este revela por qué el enfoque híbrido resiste frente al fracaso del modelo técnico en el S&P 500. El **Modelo Base** (subfiguras 6.8a y 6.8b) presenta una asignación asimétrica que concentra el 53,51 % del capital en un único activo (ABNB), utilizándolo como principal reserva de valor en un entorno desconocido, mientras reduce el resto de posiciones a niveles inferiores al 7 %. A pesar de esta concentración inicial, su matriz de correlación demuestra la existencia de diversificación, con la mayoría de sus cruces entre el 0 y 0.25 y dos máximo aislados de 0,45 y 0,47 entre HD con BBY y AVB, lo que protege la cartera ante choques cruzados.

Por el contrario, el **Modelo Dinámico** (subfiguras 6.8c y 6.8d) exhibe una diversificación ficticia. Aunque reparte sus pesos principales de forma más homogénea (SWK con 24,90 % y LVS con 22,36 %), la matriz de correlación muestra correlación ligeramente mayor a las vistas anteriormente, registrando correlaciones peligrosas de hasta 0,55 (SWK con DHI, HPQ y KKR). Al prescindir de filtros contables, el algoritmo se vuelve ciego y agrupa simultáneamente activos con patrones de precio idénticos al perseguir el *momentum* a corto plazo. Esta alta correlación interna multiplica el riesgo sistémico y explica de forma empírica su claudicación en la curva de capital: ante

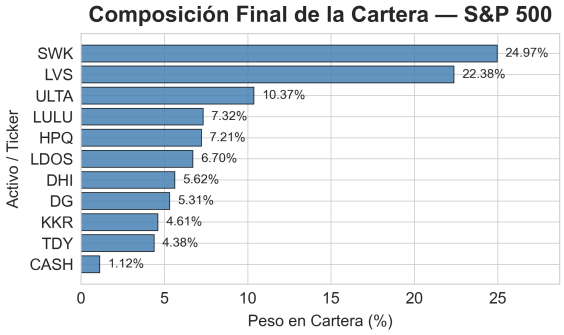
cualquier corrección de la volatilidad, la cartera arrastra sus componentes en bloque al carecer de fundamentales subyacentes que actúen como freno de seguridad.



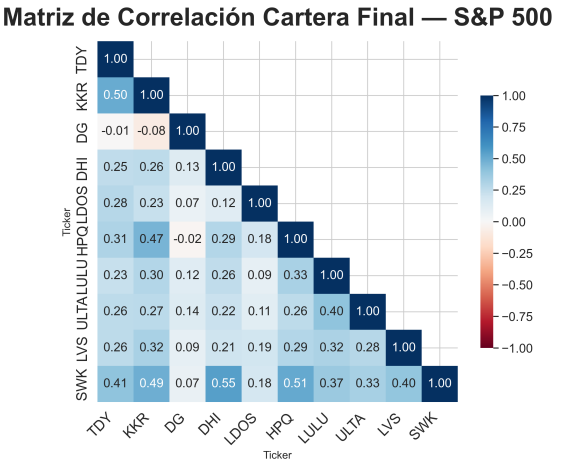
(a) Composición final - Modelo Base



(b) Correlación - Modelo Base



(c) Composición final - Modelo Dinámico



(d) Correlación - Modelo Dinámico

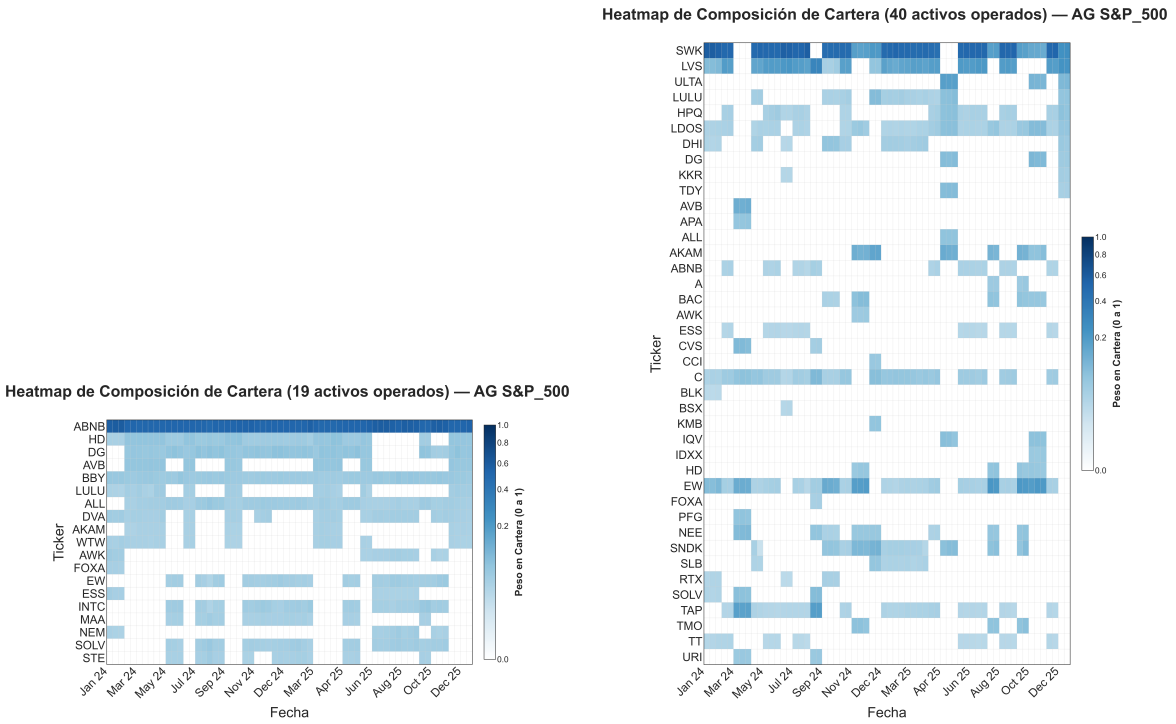
Fuente: Elaboración propia.

Figura 6.8: Análisis de la estructura interna de las carteras al cierre del periodo de generalización en el S&P 500. La primera fila (a y b) muestra la distribución de pesos y la matriz de correlación del Modelo Base. La segunda fila (c y d) expone las mismas métricas para el Modelo Dinámico.

Esta divergencia estructural vista al cierre del periodo se confirma de forma continua al analizar la evolución histórica de las ponderaciones en las figuras 6.9a y 6.9b. En el modelo base, el mapa revela un patrón de alta convicción que restringe las acciones operadas a solo 19 activos. Destaca la franja superior continua de ABNB, confirmando su papel como ancla de valor ininterrumpida durante todo el backtest. Las posiciones secundarias forman bloques estables de color, sugiriendo que el modelo adopta una postura defensiva que minimiza la rotación y aísla la cartera del ruido diario.

Por el contrario, el modelo dinámico ilustra perfectamente su ceguera estructural. Al carecer de filtros contables, dispara su actividad operando 40 activos, mostrando

un comportamiento más simil a los vistos en las figuras 8.6. Las constantes entradas y salidas sugieren que el algoritmo trata de perseguir el *momentum* a muy corto plazo. Esta reactividad técnica le impide mantener el capital en tendencias sólidas y explica visualmente por qué, al estar sus componentes tan correlacionados, la cartera sufre caídas más pronunciadas ante episodios de volatilidad.



(a) Modelo Base (b) Modelo Dinámico

Figura 6.9: Evolución temporal de la composición de la cartera del S&P 500. a) Modelo Base, y b) Modelo Dinámico
Fuente: Elaboración propia.

En resumen, la lectura de estos resultados exige contextualizar el severo choque entre regímenes de mercado. El algoritmo fue entrenado en el IBEX, un mercado con un claro sesgo *Value*, y se ha evaluado frente al S&P 500, un entorno dominado estructuralmente por el factor *Growth* y múltiplos de valoración agresivos. Por consiguiente, la robustez del modelo no debe medirse por la captura de retornos como en los modelos del IBEX, sino porque se ha demostrado la capacidad de exportar y aplicar el algoritmo en un mercado completamente diferente adaptando su conocimiento de la bolsa española para operar en la bolsa americana.

Capítulo 7

Conclusiones y Léneas Futuras

7.1. Conclusiones

El desarrollo y comprobación de este agente gestor demuestra la viabilidad de optimizar la asignación de activos a modelos de optimización heurística. Si bien el algoritmo genético presenta aún margen de mejora para consolidar una estrategia consistente, su arquitectura ha probado no limitarse a replicar de forma pasiva el mercado, sino que es capaz de adaptar dinámicamente sus ponderaciones a las condiciones inherentes del mercado.

El estudio de sensibilidad constata que, al privar a la red de los datos fundamentales y forzarla a depender de forma exclusiva de indicadores técnicos, el agente se vuelve estructuralmente ciego e hiperreactivo al ruido de corto plazo. Esta excesiva dependencia de la acción del precio penaliza la cartera, arrastrando el *drawdown* hasta el -23,67 %. Por el contrario, la integración de la taxonomía contable actúa como un mecanismo estabilizador que modera y optimiza la respuesta del agente frente a la volatilidad del mercado.

Para auditar el modelo y descartar el sesgo de la *caja negra*, la aplicación de Inteligencia Artificial Explicable (XAI) ha resultado imprescindible para entender el modelo. El entrenamiento del modelo sustituto (*Random Forest*) y la extracción de los valores SHAP confirman que el agente híbrido no se limita a memorizar ruido estadístico, sino que interioriza una lógica económica coherente. La red prioriza sistemáticamente métricas fundamentales, relegando los osciladores técnicos a un papel secundario de optimización temporal de las entradas dentro de la arquitectura completa.

Finalmente, la prueba de generalización cruzada en el S&P 500 respalda la ausencia de *overfitting* respecto al mercado local. Extrapolar un algoritmo entrenado en el IBEX 35, un índice con fuerte sesgo al *value*, a un entorno dominado por el factor *growth* como el estadounidense representa un escenario completamente contrario al presentado al algoritmo. Aunque los rendimientos brutos en este nuevo ecosistema han sido mo-

destos, el agente ha demostrado una notable capacidad de adaptación a un universo de inversión desconocido, logrando contener las pérdidas estructurales frente al colapso del modelo puramente técnico e, incluso, generando retornos positivos en su versión híbrida.

En definitiva, este trabajo concluye que el verdadero potencial del *Machine Learning* en la gestión cuantitativa trasciende la simple persecución de anomalías de alta frecuencia basadas en el precio. La auténtica ventaja estructural reside en la capacidad de la IA para procesar simultáneamente datos fundamentales, técnicos y de sentimiento de mercado (NLP) (Bhuiyan et al., 2025). La convergencia de este rigor contable con la computación evolutiva sienta las bases empíricas para el desarrollo de herramientas institucionales diseñadas no solo para rentabilizar el capital, sino para sobrevivir a escenarios de incertidumbre (Alfzari et al., 2025).

7.2. Líneas de Investigación Futuras

Durante el proceso de desarrollo del proyecto, se han ido anotando posibles líneas futuras de investigación que permitan optimizar más la idea de un algoritmo gestor de carteras basado en *cajas negras*:

- **Aplicación de combinaciones binarias:** Las combinaciones binarias se refieren a ordenes mandadas de forma completamente discrecional al algoritmo para tomar decisiones de forma automática en caso de que alguna de las características cumpla una de las combinaciones establecidas. En este proyecto no se han aplicado combinaciones binarias dado que la investigación se centraba en evaluar como se comporta el algoritmo frente a la libertad de operar en el mercado como el decida.

- **Ampliación del espacio de estados:** Si bien la red actual ha demostrado asimilar un amplio espectro de datos, la capacidad del algoritmo genético puede expandirse integrando métricas que capturen el riesgo sistémico. La inclusión de variables macroeconómicas y de mercado, como el indicador de volatilidad VIBEX o la Beta dinámica de los activos, proporcionaría al modelo nuevas dimensiones observables. Esto permitiría al algoritmo mapear y explotar relaciones latentes más profundas entre el universo de inversión y el entorno macroeconómico, asumiendo el consecuente incremento en la carga computacional.

- **Sofisticación de la función de *fitness*:** La función de aptitud constituye el núcleo que define el mandato de gestión del algoritmo. Aunque en este proyecto se ha optado por un enfoque de variable única para aislar la interpretabilidad de las decisiones del agente, la evolución del sistema requiere arquitecturas de optimización más complejas. La transición hacia funciones de penalización asimétrica,

como la incorporación del Valor en Riesgo (VaR) o diferentes ratios dentro de la ecuación de *fitness*, resultaría clave para que el algoritmo pueda identificar, medir y minimizar explícitamente el riesgo de cola de la cartera.

- **Transición hacia *Deep Reinforcement Learning* (DRL):** Aunque el Algoritmo Genético ha probado su eficacia en la optimización de pesos mediante ventanas temporales discretas, su arquitectura actual carece de memoria secuencial profunda. La evolución natural del motor de toma de decisiones pasa por sustituir este optimizador heurístico por agentes de aprendizaje por refuerzo profundo, tales como los modelos PPO (*Proximal Policy Optimization*). Esta actualización dotaría al sistema de la capacidad analítica necesaria para aprender políticas de rebalanceo continuo, secuencial y fuertemente dependientes de la trayectoria. (Jang y Seong, 2023)

Bibliografía

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: a next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, 2623-2631.

Alfzari, S., Al-Shboul, M., & Alshurideh, M. (2025). Predictive Analytics in Portfolio Management: A Fusion of AI and Investment Economics for Optimal Risk-Return Trade-Offs. *International Review of Management and Marketing*, *15*(2), 365-380. https://doi.org/10.32479/irmm.18594

Ambuli, T., Venkatesan, S., Sampath, K., Devi, K., & Kumaran, S. (2024). AI-Driven Financial Management Optimizing Investment Portfolios through Machine Learning. *2024 7th International Conference on Circuit Power and Computing Technologies (ICCPCT)*, 1822-1828. https://doi.org/10.1109/ICCPCT61902.2024.10672859

bards.ai. (2024). Finance sentiment ES (base). https://huggingface.co/bardsai/finance-sentiment-es-base

Beyhan, H., & Ulengin, B. (2023). Does more intelligent trading strategy win? Interacting trading strategies: an agent-based approach. *Journal of Intelligence Studies in Business*, *12*(3), 54-65. https://doi.org/10.37380/jisib.v12i3.929

Bhuiyan, M. S. M., Rafi, M. A., Rodrigues, G. N., Mir, M. N. H., Ishraq, A., Mridha, M., & Shin, J. (2025). Deep learning for algorithmic trading: A systematic review of predictive models and optimization strategies. *Array*, *26*, 100390. https://doi.org/10.1016/j.array.2025.100390

Brenner, L., & Meyll, T. (2020). Robo-advisors: A substitute for human financial advice? *Journal of Behavioral and Experimental Finance*, *25*, 100275. https://doi.org/10.1016/j.jbef.2020.100275

Cano, C. A. G., & Sánchez, C. A. P. (2024). La revolución de los modelos transformadores en procesamiento de lenguaje natural: Un análisis comparativo de arquitecturas y aplicaciones.

Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2023, agosto). Spanish Pre-trained BERT Model and Evaluation Data [arXiv:2308.02976 [cs]]. https://doi.org/10.48550/arXiv.2308.02976

Chang, T.-J., Meade, N., Beasley, J., & Sharaiha, Y. (2000). Heuristics for cardinality constrained portfolio optimisation. *Computers & Operations Research*, *27*(13), 1271-1302. https://doi.org/10.1016/S0305-0548(99)00074-X

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019, mayo). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding [arXiv:1810.04805 [cs]]. https://doi.org/10.48550/arXiv.1810.04805

D'Hondt, C., De Winne, R., Ghysels, E., & Raymond, S. (2020). Artificial Intelligence Alter Egos: Who might benefit from robo-investing? *Journal of Empirical Finance*, *59*, 278-299. https://doi.org/10.1016/j.jempfin.2020.10.002

Fama, E. F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, *25*(2), 383-417. https://doi.org/10.2307/2325486

Fama, E. F., & French, K. R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, *116*(1), 1-22. https://doi.org/10.1016/j.jfineco.2014.10.010

Fernández, M. (2022). La CNMV suspende la cotización de Ezentis en plena reestructuración. *El País*. https://elpais.com/economia/2022-12-02/la-cnmv-suspende-la-cotizacion-de-ezentis-en-plena-reestructuracion.html

Gilli, M., & Këllezi, E. (2004). *An application of evolutionary computing to portfolio optimization* [tex.howpublished: University of Geneva Digital Repository]. https://www.unige.ch/ses/dsec/static/gilli/CyprusLecture2004.pdf

Gonzalez, I. C. (2020). Procesamiento del lenguaje natural con BERT: Análisis de sentimientos en tuits.

(GranData), D. L. P. (2020). Technical analysis library implemented in python users. https://github.com/bukosabino/ta

Jang, J., & Seong, N. (2023). Deep reinforcement learning for stock portfolio optimization by connecting with modern portfolio theory. *Expert Systems with Applications*, *218*, 119556. https://doi.org/10.1016/j.eswa.2023.119556

Jiang, Z., Xu, D., & Liang, J. (2017, julio). A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem [arXiv:1706.10059 [q-fin]]. https://doi.org/10.48550/arXiv.1706.10059

Kahneman, D., & Tversky, A. (1979). Prospect Theory: An Analysis of Decision under Risk. *Econometrica*, *47*(2), 263-291. https://doi.org/10.2307/1914185

London Stock Exchange Group. (2026). LSEG API samples: Code examples for LSEG data & analytics apis. https://github.com/LSEG-API-Samples

López De Prado, M. M. (2020, abril). *Machine Learning for Asset Managers* (1.ª ed.). Cambridge University Press. https://doi.org/10.1017/9781108883658

López De Prado, M. M., Lipton, A., & Zoonekynd, V. (2025). HOW TO USE THE SHARPE RATIO.

Lundberg, S., & Lee, S.-I. (2017). A unified approach to interpreting model predictions [arXiv: 1705.07874 [cs.AI]]. https://arxiv.org/abs/1705.07874

Luo, H., Liu, X., Lv, X., Hu, Y., & Ahmad, A. J. (2024). Investors' willingness to use robo-advisors: Extrapolating influencing factors based on the fiduciary duty of investment advisors. *International Review of Economics & Finance*, *94*, 103411. https://doi.org/10.1016/j.iref.2024.103411

Markowitz, H. M. (1959). *Portfolio Selection*. Yale University Press. Consultado el 18 de abril de 2026, desde http://www.jstor.org/stable/j.ctt1bh4c8h

Michalewicz, Z. (1996). *Genetic algorithms + data structures = evolution programs* (3rd). Springer Science & Business Media.

Molnar, C., Casalicchio, G., & Bischl, B. (2020). Interpretable machine learning – a brief history, state-of-the-art and challenges. En *ECML PKDD 2020 workshops* (pp. 417-431). Springer International Publishing. https://doi.org/10.1007/978-3-030-65965-3_28

Moosa, A., AlKhena, M. K., Ali, M., & Kumaraswamy, S. (2024). Beyond Tradition: The AI Frontier in Portfolio Management. *2024 International Conference on Sustainable Islamic Business and Finance (SIBF)*, 1-6. https://doi.org/10.1109/SIBF63788.2024.10883839

Perlin, M. S., Foguesatto, C. R., Müller, F. M., & Righi, M. B. (2025). Can AI beat a naive portfolio? An experiment with anonymized data. *Finance Research Letters*, *78*, 107126. https://doi.org/10.1016/j.frl.2025.107126

Serur, J. A., & Avellaneda, M. (2020). Hierarchical PCA and Modeling Asset Correlations. *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.3903460

Sharpe, W. F. (1964). Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk. *The Journal of Finance*, *19*(3), 425-442. https://doi.org/10.2307/2977928

Sheptyuk Riabchynskiy, M. (2025). *Prediccion de tendencias en series temporales financieras mediante algoritmos de machine learning y tecnicas avanzadas de feature engineering* [Tesis doctoral]. https://hdl.handle.net/20.500.12880/13621

Thomson Reuters. (2016, julio). Thomson reuters business classification.

Towers, M., Terry, J. K., Antonis, A., Balis, M., Opasiak, F., Bal, S., Black, B., Hessenberger, L., Kwiatkowski, R., Lukashov, D., et al. (2023). Gymnasium. https://github.com/Farama-Foundation/Gymnasium

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023, agosto). Attention Is All You Need [arXiv:1706.03762 [cs]]. https://doi.org/10.48550/arXiv.1706.03762

Xu, J., Chau, H., & Burden, A. (2025, febrero). From Abstract to Actionable: Pairwise Shapley Values for Explainable AI [arXiv:2502.12525 [cs.LG]]. https://doi.org/10.48550/arXiv.2502.12525

Yang, N., Fernandez-Perez, A., & Indriawan, I. (2024). Spillover between investor sentiment and volatility: The role of social media. *International Review of Financial Analysis*, *96*, 103643. https://doi.org/https://doi.org/10.1016/j.irfa.2024.103643

Capítulo 8

Anexo

8.1. Anexo: Código

Los scripts utilizados para la realización del proyecto se han guardado en el siguiente repositorio.
Repositorio: https://github.com/ricardoespana/Optimizacion-Evolutiva-de-Carteras

Los paquetes utilizados durante todo el proyecto que no han sido mencionados en el proyecto son los siguientes:

1. Extracción y Conexión de Datos Financieros

- **LSEG API** (`lseg-data`): Obtención del universo de activos según el índice de estudio, datos de cotización y métricas fundamentales.
- `gnews`: Extracción y *web scraping* de noticias financieras.

2. Manipulación de Datos y Análisis Técnico

- `pandas`: Motor principal para la limpieza de datos, cruce de información y gestión de series temporales.
- `numpy`: Soporte para cálculos numéricos avanzados y operaciones vectorizadas.
- `pandas_ta` / `ta`: Cálculo de indicadores técnicos (SMA, OBV, ATR, etc.).

3. Procesamiento de Lenguaje Natural (NLP)

- `torch` **(PyTorch)**: Motor de cálculo tensorial base para la ejecución de modelos *transformers*

- `transformers`: Herramientas de análisis de sentimiento para la evaluación.

4. Entornos de Simulación

- `gymnasium` **(o** `gym`**)**: Creación del entorno de simulación secuencial (*step, reset, render*) para la interacción del algoritmo de asignación.

5. Machine Learning

- `scikit-learn`: Entrenamiento, parametrización y evaluación de los modelos de *Random Forest*.

6. Explicabilidad y Visualización

- `shap`: Herramienta de Inteligencia Artificial Explicable para calcular los valores SHAP.

- `matplotlib`: Construcción de gráficas.

- `seaborn`: Generación de gráficos de distribución y visualización estadística.

8.2. Anexo: Cuadros

Cuadro 8.1: Listado de empresas por índice, sector e industria

Ticker	Nombre	Sector	Industria	Índice
COL.MC	Colonial SFL SOCIMI SA	Real Estate	Commercial REITs	IBEX 35
UNI.MC	Unicaja Banco SA	Financials	Banks	IBEX 35
LOG.MC	Logista Integral SA	Industrials	Courier, Postal, Air Freight & Land-based Logistics	IBEX 35
ICAG.MC	International Consolidated Airlines Group SA	Industrials	Airlines	IBEX 35
ELE.MC	Endesa SA	Utilities	Electric Utilities	IBEX 35
GRLS.MC	Grifols SA	Healthcare	Pharmaceuticals	IBEX 35
IBE.MC	Iberdrola SA	Utilities	Electric Utilities	IBEX 35
NTGY.MC	Naturgy Energy Group SA	Utilities	Natural Gas Utilities	IBEX 35
ANA.MC	Acciona SA	Industrials	Construction & Engineering	IBEX 35
REDE.MC	Redeia Corporacion SA	Utilities	Electric Utilities	IBEX 35
SLRS.MC	Solaria Energia y Medio Ambiente SA	Utilities	Independent Power Producers	IBEX 35
ACX.MC	Acerinox SA	Basic Materials	Iron & Steel	IBEX 35
SAN.MC	Banco Santander SA	Financials	Banks	IBEX 35
AENA.MC	Aena SME SA	Industrials	Airport Operators & Services	IBEX 35
FLUI.MC	Fluidra SA	Consumer Cyclicals	Recreational Products	IBEX 35
MAP.MC	Mapfre SA	Financials	Multiline Insurance & Brokers	IBEX 35
SABE.MC	Banco de Sabadell SA	Financials	Banks	IBEX 35
CABK.MC	CaixaBank SA	Financials	Banks	IBEX 35
MTS.MC	ArcelorMittal SA	Basic Materials	Iron & Steel	IBEX 35
CLNX.MC	Cellnex Telecom S.a	Technology	Wireless Telecommunications Services	IBEX 35
TEF.MC	Telefonica SA	Technology	Integrated Telecommunications Services	IBEX 35
MRL.MC	MERLIN Properties SOCIMI SA	Real Estate	Commercial REITs	IBEX 35
FER.MC	Ferrovial SE	Industrials	Construction & Engineering	IBEX 35
ENAG.MC	Enagas SA	Energy	Oil & Gas Transportation Services	IBEX 35
ANE.MC	Corporacion Acciona Energias Renovables SA	Utilities	Electric Utilities	IBEX 35
ITX.MC	Industria de Diseno Textil SA	Consumer Cyclicals	Apparel & Accessories Retailers	IBEX 35
BBVA.MC	Banco Bilbao Vizcaya Argentaria SA	Financials	Banks	IBEX 35
ACS.MC	ACS Actividades de Construccion y Servicios SA	Industrials	Construction & Engineering	IBEX 35
PUIGb.MC	Puig Brands SA	Consumer Cyclicals	Miscellaneous Specialty Retailers	IBEX 35
IDR.MC	Indra Sistemas SA	Technology	IT Services & Consulting	IBEX 35
SCYR.MC	Sacyr SA	Industrials	Construction & Engineering	IBEX 35
ROVI.MC	Laboratorios Farmaceuticos ROVI SA	Healthcare	Pharmaceuticals	IBEX 35
REP.MC	Repsol SA	Energy	Oil & Gas Refining and Marketing	IBEX 35
BKT.MC	Bankinter SA	Financials	Banks	IBEX 35
AMA.MC	Amadeus IT Group SA	Technology	IT Services & Consulting	IBEX 35
FAE.MC	Faes Farma SA	Healthcare	Pharmaceuticals	IBEX_MEDIUM_
HOME.MC	Neinor Homes SA	Real Estate	Real Estate Rental, Development & Operations	IBEX_MEDIUM_

Cuadro 8.1: Listado de empresas por índice, sector e industria (continuación)

Ticker	Nombre	Sector	Industria	Índice
VIS.MC	Viscofan SA	Basic Materials	Non-Paper Containers & Packaging	IBEX_MEDIU
CIRSA.MC	Cirsa Enterprises SAU	Consumer Cyclicals	Casinos & Gaming	IBEX_MEDIU
DIDA.MC	Distribuidora Internacional de Alimentacion SA	Consumer Non-Cyclicals	Food Retail & Distribution	IBEX_MEDIU
PHMR.MC	Pharma Mar SA	Healthcare	Pharmaceuticals	IBEX_MEDIU
A3M.MC	Atresmedia Corporacion de Medios de Comunicacion SA	Consumer Cyclicals	Broadcasting	IBEX_MEDIU
TUBA.MC	Tubacex SA	Basic Materials	Iron & Steel	IBEX_MEDIU
ENOR.MC	Elecnor SA	Industrials	Construction & Engineering	IBEX_MEDIU
CIEA.MC	CIE Automotive SA	Consumer Cyclicals	Auto, Truck & Motorcycle Parts	IBEX_MEDIU
EBRO.MC	Ebro Foods SA	Consumer Non-Cyclicals	Food Processing	IBEX_MEDIU
TRE.MC	Tecnicas Reunidas SA	Industrials	Construction & Engineering	IBEX_MEDIU
LDA.MC	Linea Directa Aseguradora SA Compania de Seguros y Reaseguros	Financials	Property & Casualty Insurance	IBEX_MEDIU
HBX.MC	HBX Group International PLC	Technology	Online Services	IBEX_MEDIU
CAF.MC	Construcciones y Auxiliar de Ferrocarriles SA	Industrials	Heavy Machinery & Vehicles	IBEX_MEDIU
GEST.MC	Gestamp Automocion SA	Consumer Cyclicals	Auto, Truck & Motorcycle Parts	IBEX_MEDIU
VID.MC	Vidrala SA	Basic Materials	Non-Paper Containers & Packaging	IBEX_MEDIU
GREG.MC	Grenergy Renovables SA	Utilities	Independent Power Producers	IBEX_MEDIU
MEL.MC	Melia Hotels International SA	Consumer Cyclicals	Hotels, Motels & Cruise Lines	IBEX_MEDIU
ALM.MC	Almirall SA	Healthcare	Pharmaceuticals	IBEX_MEDIU
ATRY.MC	Atrys Health SA	Healthcare	Healthcare Facilities & Services	IBEX_SMALL
AI.MC	Airtificial Intelligence Structures SA	Technology	Electronic Equipment & Parts	IBEX_SMALL
AZK.MC	Azkoyen SA	Industrials	Industrial Machinery & Equipment	IBEX_SMALL
DOMI.MC	Global Dominion Access SA	Industrials	Business Support Services	IBEX_SMALL
TLGO.MC	Talgo SA	Industrials	Heavy Machinery & Vehicles	IBEX_SMALL
OHLA.MC	Obrascon Huarte Lain SA	Industrials	Construction & Engineering	IBEX_SMALL
ENC.MC	Ence Energia y Celulosa SA	Basic Materials	Paper Products	IBEX_SMALL
ALNTA.MC	Alantra Partners SA	Financials	Investment Management & Fund Operators	IBEX_SMALL
ADXR.MC	Audax Renovables SA	Utilities	Multiline Utilities	IBEX_SMALL
NXTE.MC	Nueva Expresion Textil SA	Consumer Cyclicals	Textiles & Leather Goods	IBEX_SMALL
OLEO.MC	Deoleo SA	Consumer Non-Cyclicals	Food Processing	IBEX_SMALL
GSJ.MC	Grupo Empresarial San Jose SA	Industrials	Construction & Engineering	IBEX_SMALL
ORY.MC	Oryzon Genomics SA	Healthcare	Biotechnology & Medical Research	IBEX_SMALL
RJFE.MC	Laboratorio Reig Jofre SA	Healthcare	Pharmaceuticals	IBEX_SMALL
EDRE.MC	eDreams ODIGEO SA	Consumer Cyclicals	Leisure & Recreation	IBEX_SMALL
APE.MC	Amper SA	Technology	Communications & Networking	IBEX_SMALL
ECNER.MC	Ecoener SA	Utilities	Independent Power Producers	IBEX_SMALL

Cuadro 8.1: Listado de empresas por índice, sector e industria (continuación)

Ticker	Nombre	Sector	Industria	Índice
TUR.MC	Tubos Reunidos SA	Basic Materials	Iron & Steel	IBEX_SMALL_CA
CASHP.MC	Prosegur Cash SA	Industrials	Business Support Services	IBEX_SMALL_CA
GAMQ.MC	General de Alquiler de Maquinaria SA	Industrials	Business Support Services	IBEX_SMALL_CA
VOC.MC	Vocento SA	Consumer Cyclicals	Consumer Publishing	IBEX_SMALL_CA
BKY.MC	Berkeley Energia Ltd	Basic Materials	Non-Gold Precious Metals & Minerals	IBEX_SMALL_CA
ECR.MC	Ercros SA	Basic Materials	Commodity Chemicals	IBEX_SMALL_CA
PRIM.MC	Prim SA	Healthcare	Medical Equipment, Supplies & Distribution	IBEX_SMALL_CA
NTH.MC	Naturhouse Health SA	Consumer Cyclicals	Miscellaneous Specialty Retailers	IBEX_SMALL_CA
PSG.MC	Prosegur Compania de Seguridad SA	Industrials	Business Support Services	IBEX_SMALL_CA
IZER.MC	Izertis SA	Technology	IT Services & Consulting	IBEX_SMALL_CA
EZEN.MC	Grupo Ezentis SA	Industrials	Construction & Engineering	IBEX_SMALL_CA
NEA.MC	Nicolas Correa SA	Industrials	Industrial Machinery & Equipment	IBEX_SMALL_CA
CBAV.MC	Clinica Baviera SA	Healthcare	Healthcare Facilities & Services	IBEX_SMALL_CA

Fuente: Elaboración propia a partir de los datos extraidos de London Stock Exchange Group (2026).

Cuadro 8.2: Listado de empresas del S&P500 seleccionadas aleatoriamente

Ticker	Nombre	Sector	Industria	Índice
IDXX	IDEXX Laboratories Inc	Healthcare	Medical Equipment, Supplies & Distribution	S&P 500
HBAN	Huntington Bancshares Inc	Financials	Banks	S&P 500
SNDK	Sandisk Corp	Technology	Computer Hardware	S&P 500
TAP	Molson Coors Beverage Co	Consumer Non-Cyclicals	Brewers	S&P 500
ESS	Essex Property Trust Inc	Real Estate	Residential REITs	S&P 500
BAC	Bank of America Corp	Financials	Banks	S&P 500
HPQ	HP Inc	Technology	Computer Hardware	S&P 500
ULTA	Ulta Beauty Inc	Consumer Cyclicals	Miscellaneous Specialty Retailers	S&P 500
INTC	Intel Corp	Technology	Semiconductors	S&P 500
LDOS	Leidos Holdings Inc	Technology	IT Services & Consulting	S&P 500
FOX	Fox Corp	Consumer Cyclicals	Broadcasting	S&P 500
CVS	CVS Health Corp	Healthcare	Healthcare Facilities & Services	S&P 500
AKAM	Akamai Technologies Inc	Technology	IT Services & Consulting	S&P 500
KIM	Kimco Realty Corp	Real Estate	Commercial REITs	S&P 500
ETR	Entergy Corp	Utilities	Electric Utilities	S&P 500
EXC	Exelon Corp	Utilities	Electric Utilities	S&P 500
ACN	Accenture PLC	Technology	IT Services & Consulting	S&P 500
NWSA	News Corp	Consumer Cyclicals	Consumer Publishing	S&P 500
NEM	Newmont Corporation	Basic Materials	Gold	S&P 500
LVS	Las Vegas Sands Corp	Consumer Cyclicals	Casinos & Gaming	S&P 500
A	Agilent Technologies Inc	Healthcare	Advanced Medical Equipment & Technology	S&P 500

Cuadro 8.2: Listado de empresas por índice y sector (continuación)

Ticker	Nombre	Sector	Industria	Índice
IQV	IQVIA Holdings Inc	Healthcare	Biotechnology & Medical Research	S&P 500
TTWO	Take-Two Interactive Software Inc	Technology	Software	S&P 500
NEE	Nextera Energy Inc	Utilities	Electric Utilities	S&P 500
DVA	DaVita Inc	Healthcare	Healthcare Facilities & Services	S&P 500
TT	Trane Technologies PLC	Industrials	Electrical Components & Equipment	S&P 500
DGX	Quest Diagnostics Inc	Healthcare	Healthcare Facilities & Services	S&P 500
SOLV	Solventum Corp	Healthcare	Medical Equipment, Supplies & Distribution	S&P 500
ALL	Allstate Corp	Financials	Property & Casualty Insurance	S&P 500
AJG	Arthur J. Gallagher & Co.	Financials	Multiline Insurance & Brokers	S&P 500
CDNS	Cadence Design Systems Inc	Technology	Software	S&P 500
KMB	Kimberly-Clark Corp	Consumer Non-Cyclicals	Personal Products	S&P 500
AVB	AvalonBay Communities Inc	Real Estate	Residential REITs	S&P 500
EW	Edwards Lifesciences Corp	Healthcare	Advanced Medical Equipment & Technology	S&P 500
OTIS	Otis Worldwide Corp	Industrials	Heavy Electrical Equipment	S&P 500
KKR	KKR & Co Inc	Financials	Investment Management & Fund Operators	S&P 500
PPL	PPL Corp	Utilities	Multiline Utilities	S&P 500
KDP	Keurig Dr Pepper Inc	Consumer Non-Cyclicals	Non-Alcoholic Beverages	S&P 500
UDR	UDR Inc	Real Estate	Residential REITs	S&P 500
TMO	Thermo Fisher Scientific Inc	Healthcare	Advanced Medical Equipment & Technology	S&P 500
FOXA	Fox Corp	Consumer Cyclicals	Broadcasting	S&P 500
DG	Dollar General Corp	Consumer Cyclicals	Discount Stores	S&P 500
NKE	Nike Inc	Consumer Cyclicals	Footwear	S&P 500
MKC	McCormick & Company Inc	Consumer Non-Cyclicals	Food Processing	S&P 500
LULU	Lululemon Athletica Inc	Consumer Cyclicals	Apparel & Accessories	S&P 500
URI	United Rentals Inc	Industrials	Business Support Services	S&P 500
L	Loews Corp	Financials	Property & Casualty Insurance	S&P 500
GEN	Gen Digital Inc	Technology	Software	S&P 500
BBY	Best Buy Co Inc	Consumer Cyclicals	Computer & Electronics Retailers	S&P 500
WTW	Willis Towers Watson PLC	Financials	Multiline Insurance & Brokers	S&P 500
VLO	Valero Energy Corp	Energy	Oil & Gas Refining and Marketing	S&P 500
STE	STERIS plc	Healthcare	Medical Equipment, Supplies & Distribution	S&P 500
COIN	Coinbase Global Inc	Technology	Blockchain & Cryptocurrency	S&P 500
CCI	Crown Castle Inc	Real Estate	Specialized REITs	S&P 500
BLK	BlackRock Inc	Financials	Investment Management & Fund Operators	S&P 500
EFX	Equifax Inc	Industrials	Professional Information Services	S&P 500
AMD	Advanced Micro Devices Inc	Technology	Semiconductors	S&P 500

Cuadro 8.2: Listado de empresas por índice y sector (continuación)

Ticker	Nombre	Sector	Industria	Índice
SWK	Stanley Black & Decker Inc	Industrials	Industrial Machinery & Equipment	S&P 500
ADP	Automatic Data Processing Inc	Technology	IT Services & Consulting	S&P 500
ABNB	Airbnb Inc	Technology	Online Services	S&P 500
HIG	Hartford Insurance Group Inc	Financials	Multiline Insurance & Brokers	S&P 500
BSX	Boston Scientific Corp	Healthcare	Advanced Medical Equipment & Technology	S&P 500
RTX	RTX Corp	Industrials	Aerospace & Defense	S&P 500
MPC	Marathon Petroleum Corp	Energy	Oil & Gas Refining and Marketing	S&P 500
TECH	Bio-Techne Corp	Healthcare	Biotechnology & Medical Research	S&P 500
C	Citigroup Inc	Financials	Investment Banking & Brokerage Services	S&P 500
AWK	American Water Works Co Inc	Utilities	Water & Related Utilities	S&P 500
APA	APA Corp (US)	Energy	Oil & Gas Exploration and Production	S&P 500
SLB	SLB NV	Energy	Oil Related Services and Equipment	S&P 500
PFG	Principal Financial Group Inc	Financials	Life & Health Insurance	S&P 500
DHI	D.R. Horton Inc	Consumer Cyclicals	Homebuilding	S&P 500
IP	International Paper Co	Basic Materials	Paper Packaging	S&P 500
VEEV	Veeva Systems Inc	Healthcare	Advanced Medical Equipment & Technology	S&P 500
TDY	Teledyne Technologies Inc	Technology	Electronic Equipment & Parts	S&P 500
EME	EMCOR Group Inc	Industrials	Construction & Engineering	S&P 500
V	Visa Inc	Industrials	Business Support Services	S&P 500
GLW	Corning Inc	Technology	Electronic Equipment & Parts	S&P 500
ROP	Roper Technologies Inc	Technology	Software	S&P 500
MAA	Mid-America Apartment Communities Inc	Real Estate	Residential REITs	S&P 500
HD	Home Depot Inc	Consumer Cyclicals	Home Improvement Products & Services Retailers	S&P 500

Fuente: Elaboración propia a partir de los datos extraidos de London Stock Exchange Group (2026).

8.3. Anexo: Figuras

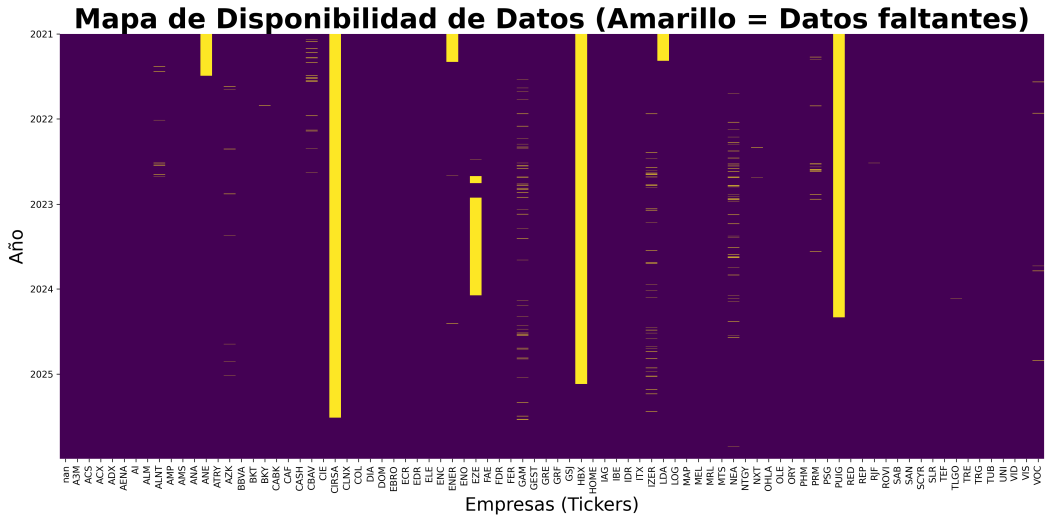


Figura 8.1: Heatmap de disponibilidad de los datos de cotización. Elaboración propia
Fuente: Elaboración propia.

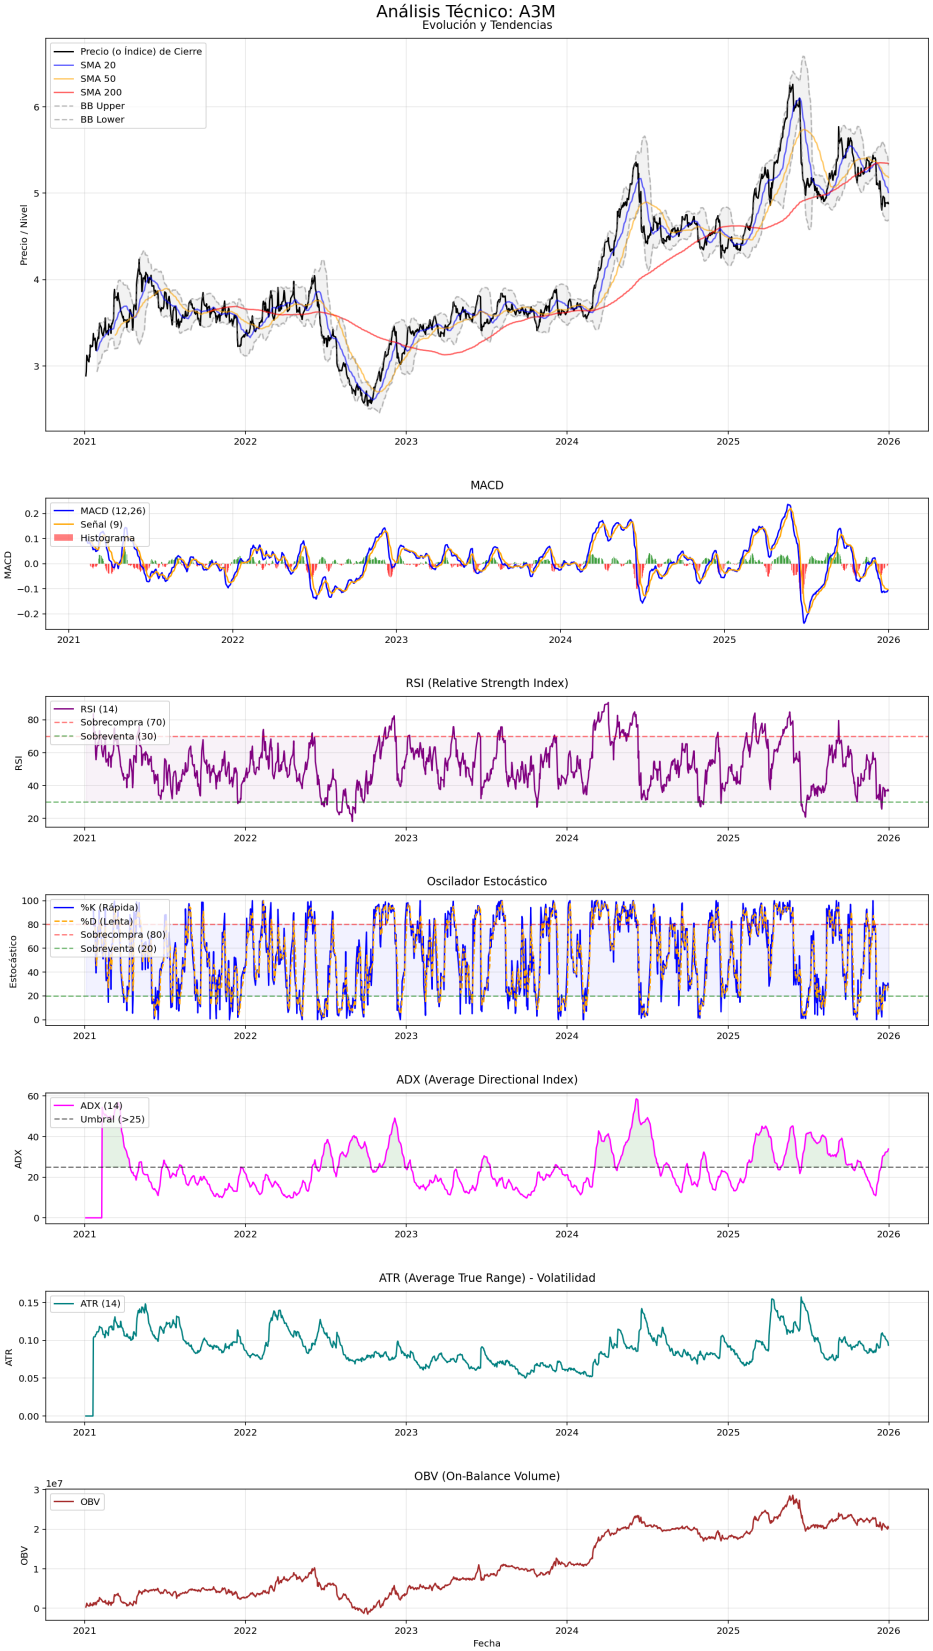
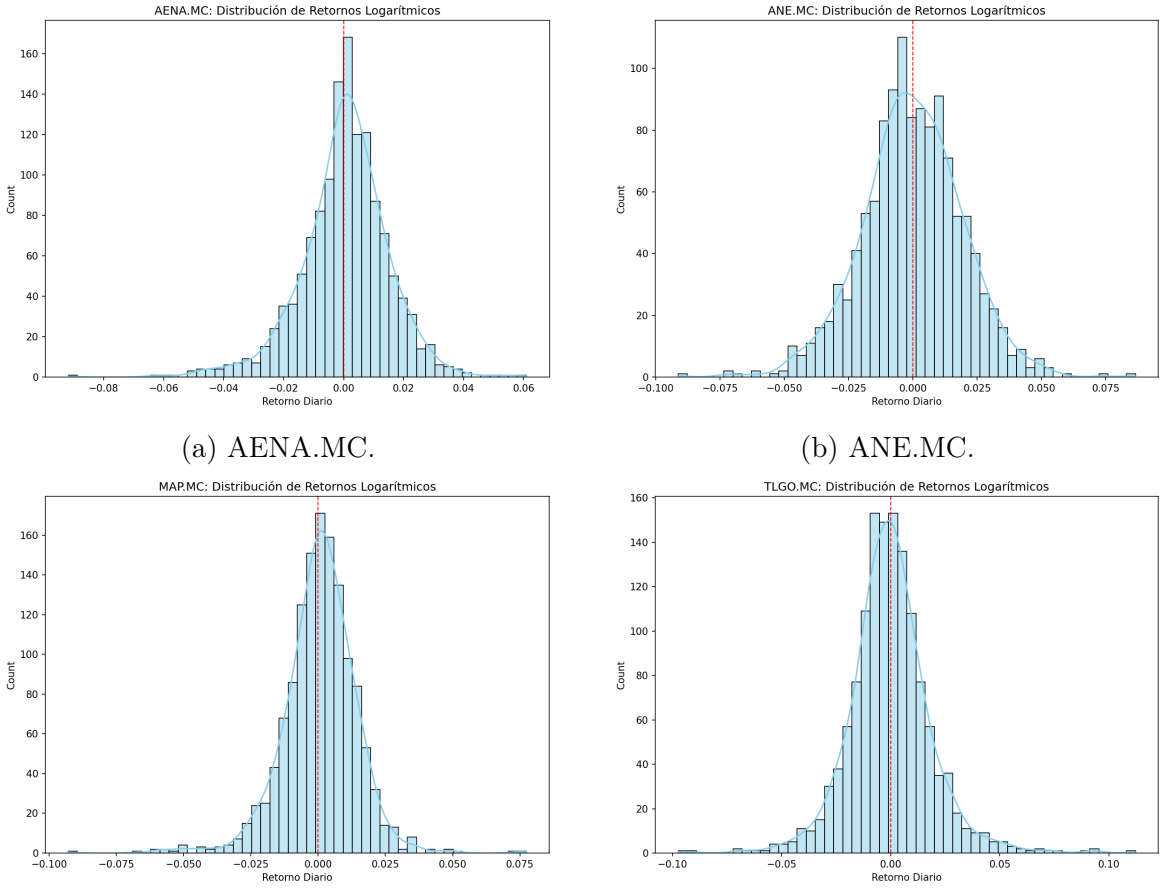


Figura 8.2: Indicadores Técnicos para la muestra de A3M

Fuente: Elaboración propia.



(a) AENA.MC.

(b) ANE.MC.

(c) MAP.MC.

(d) TLGO.MC.

Figura 8.3: Histogramas de retornos para las cuatro empresas analizadas: a) `AENA.MC`, b) `ANE.MC`, c) `MAP.MC` y d) `TLGO.MC`.
Fuente: Elaboración propia.

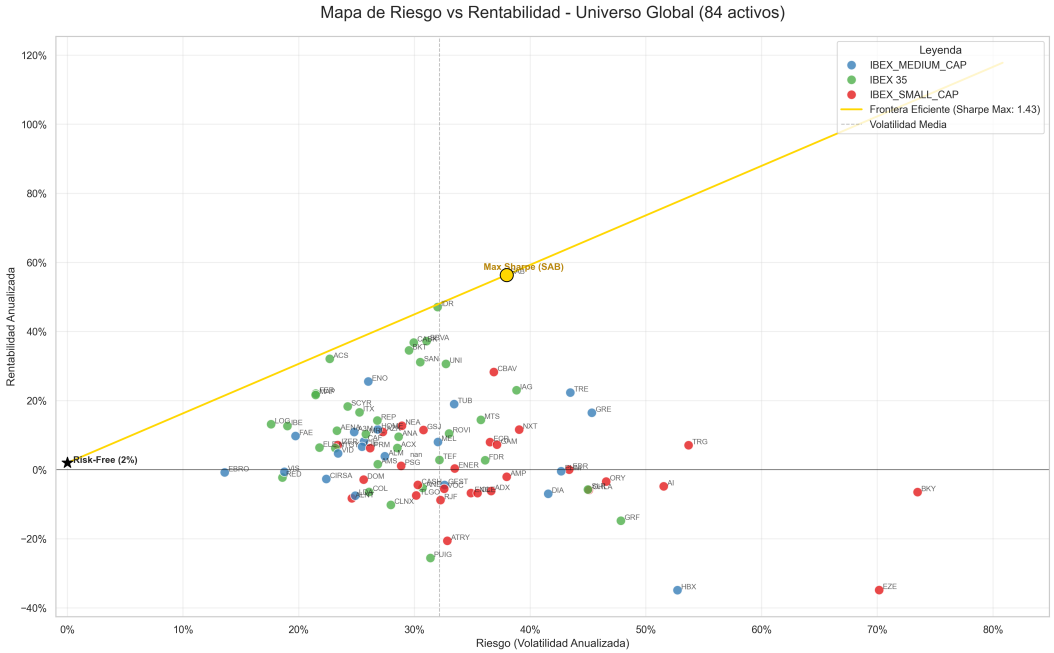


Figura 8.4: Mapa Riesgo-Rentabilidad con CML

Fuente: Elaboración propia.

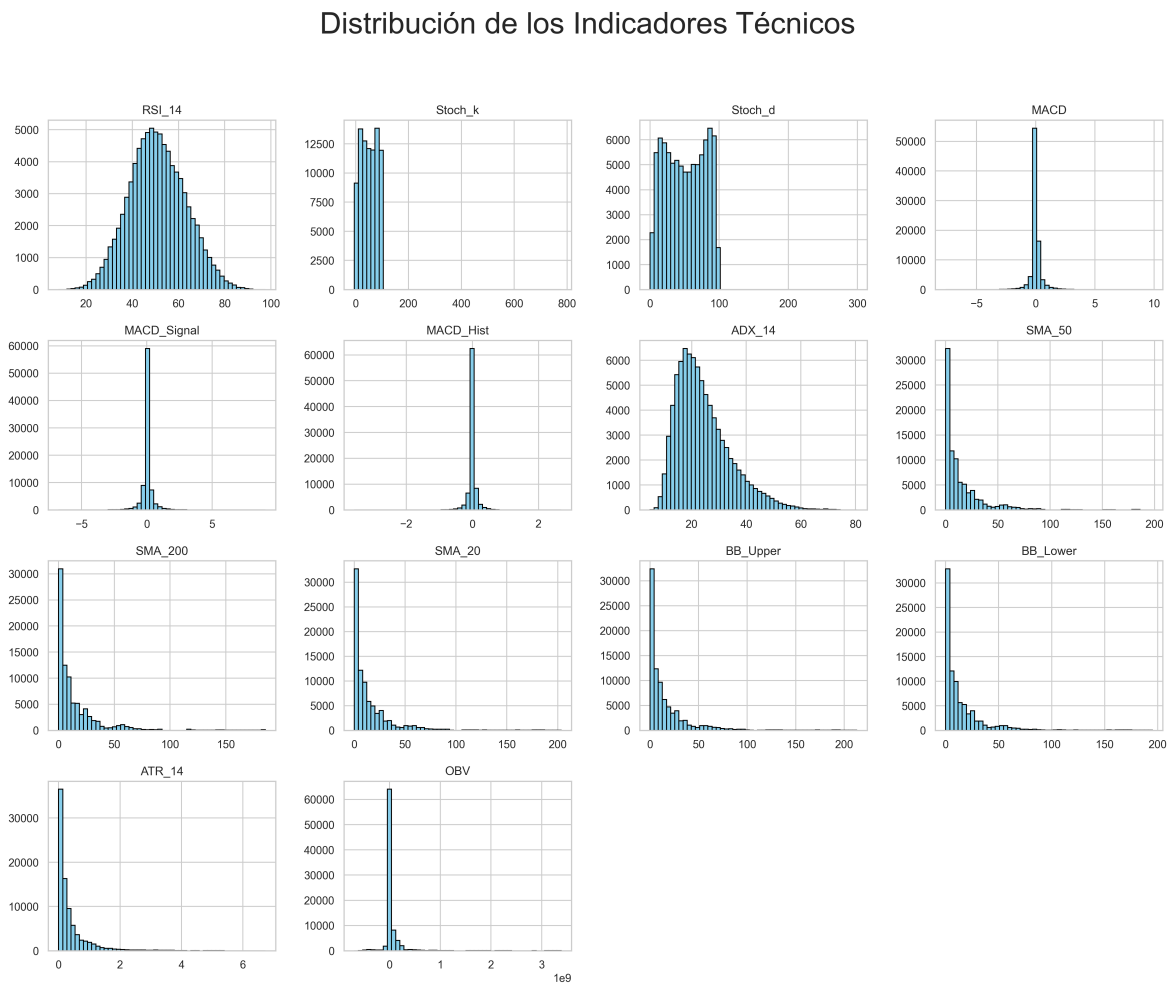
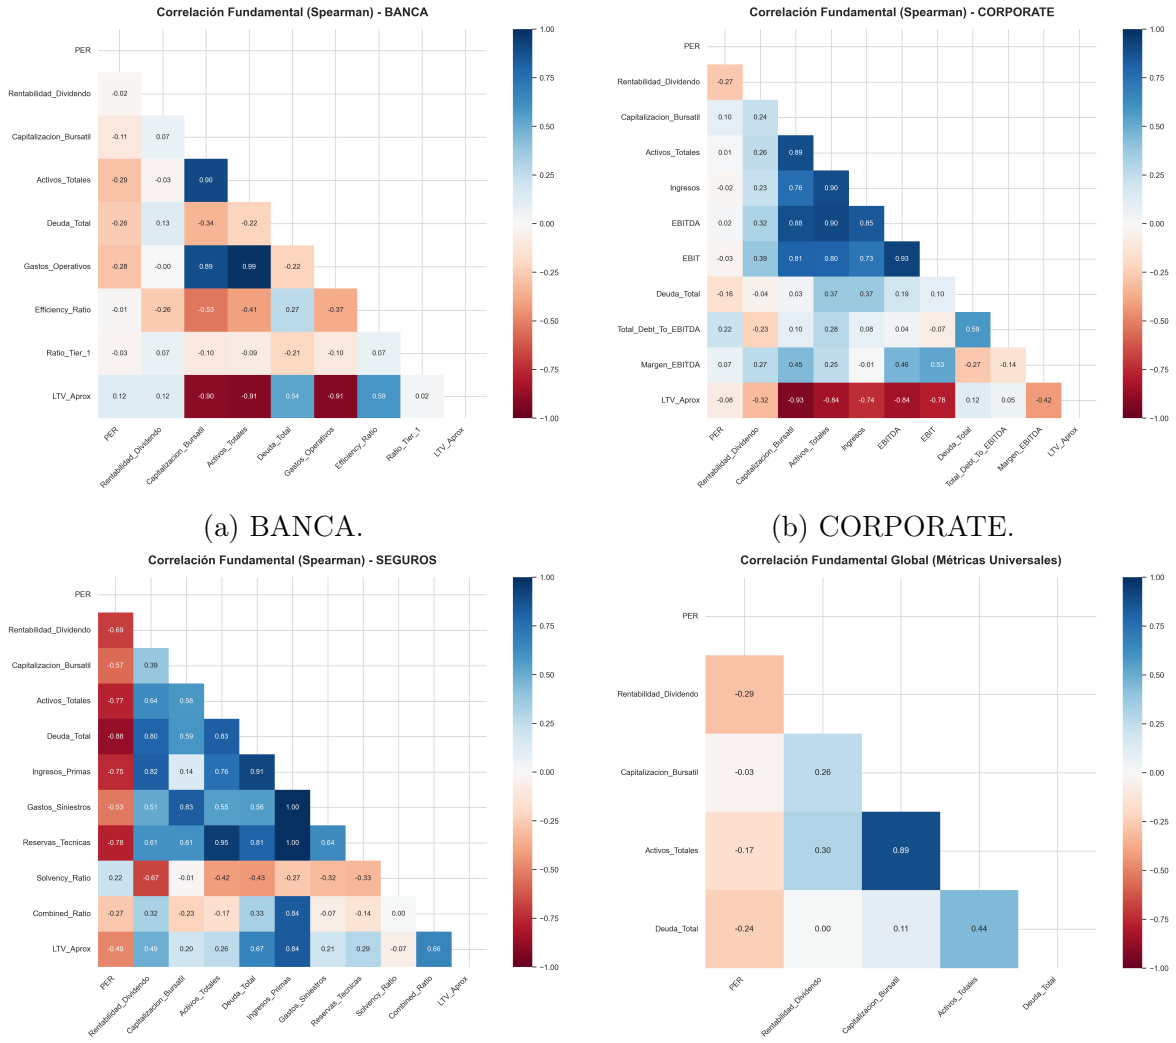


Figura 8.5: Histogramas de los indicadores técnicos

Fuente: Elaboración propia.



(a) BANCA. (b) CORPORATE.

(c) SEGUROS. (d) GLOBAL.

Figura 8.6: Correlaciones fundamentales para los diferentes sectores del IBEX: a) sector `BANCA`, b) empresas tipo `CORPORATE`, c) sector `SEGUROS` y d) análisis `GLOBAL`.
Fuente: Elaboración propia.

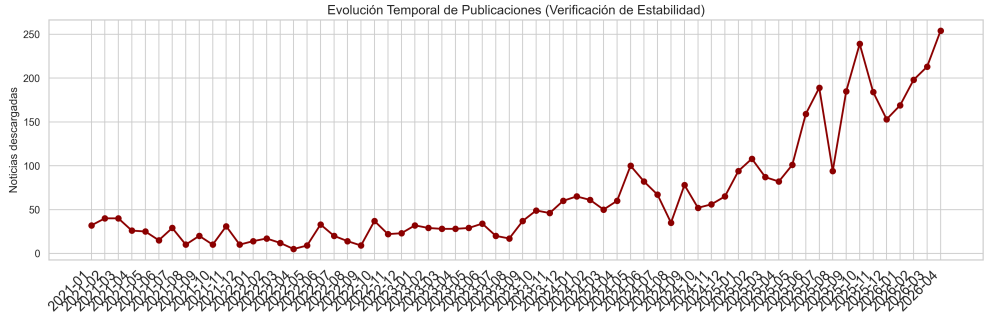


Figura 8.7: Evolución temporal de publicaciones y verificación de estabilidad.
Fuente: Elaboración propia.

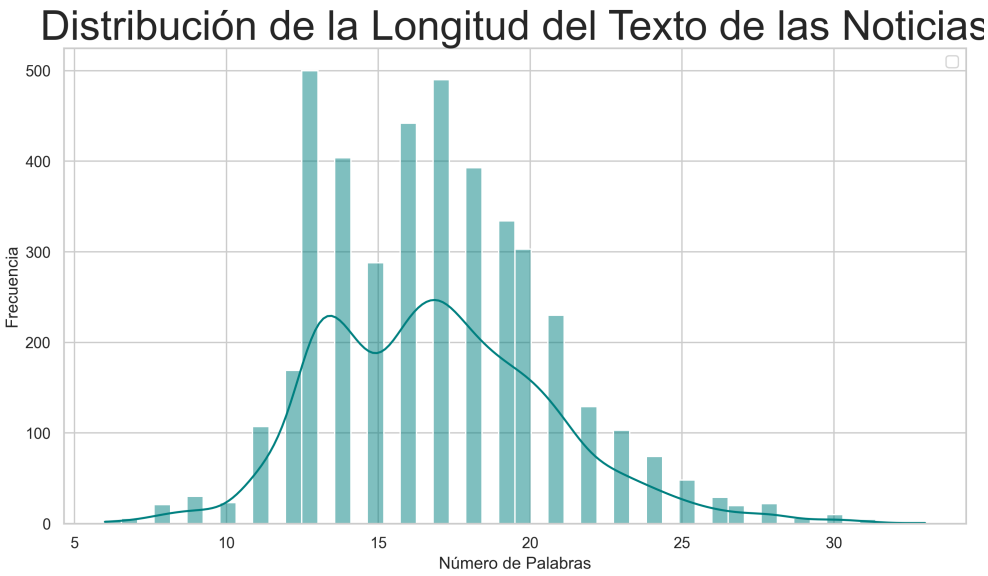


Figura 8.8: Distribución de la longitud del texto de las noticias extraídas.
Fuente: Elaboración propia.

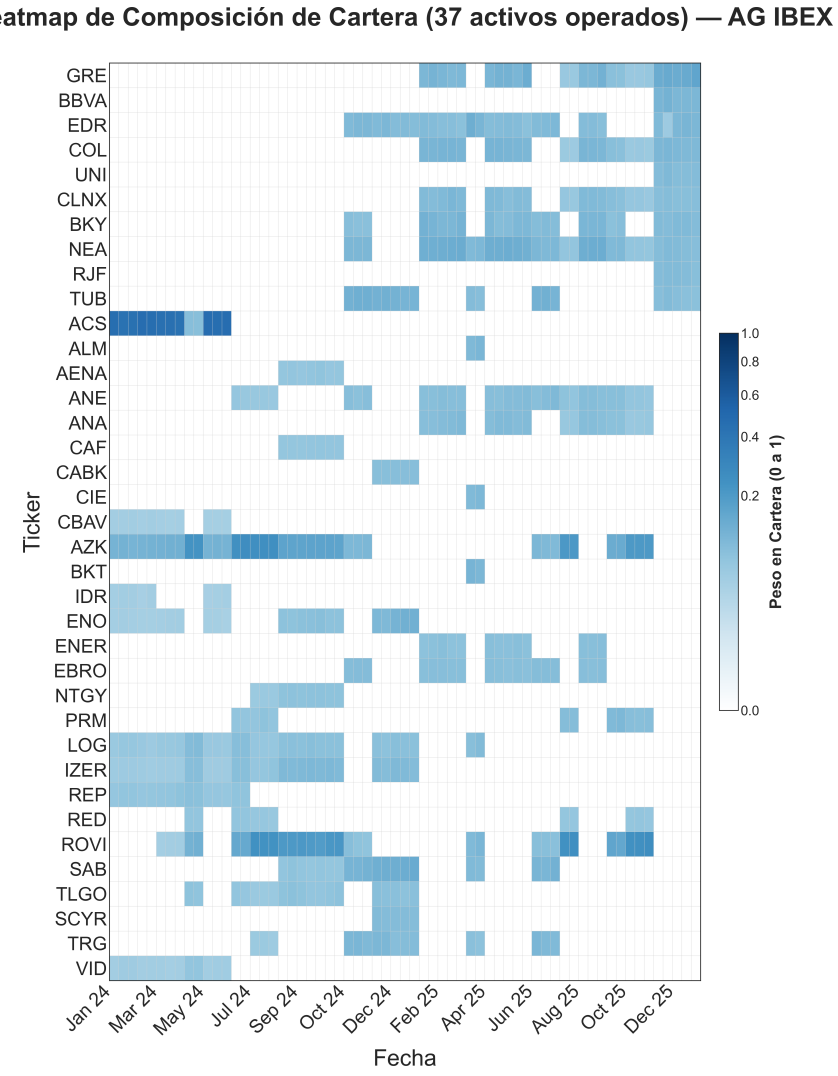
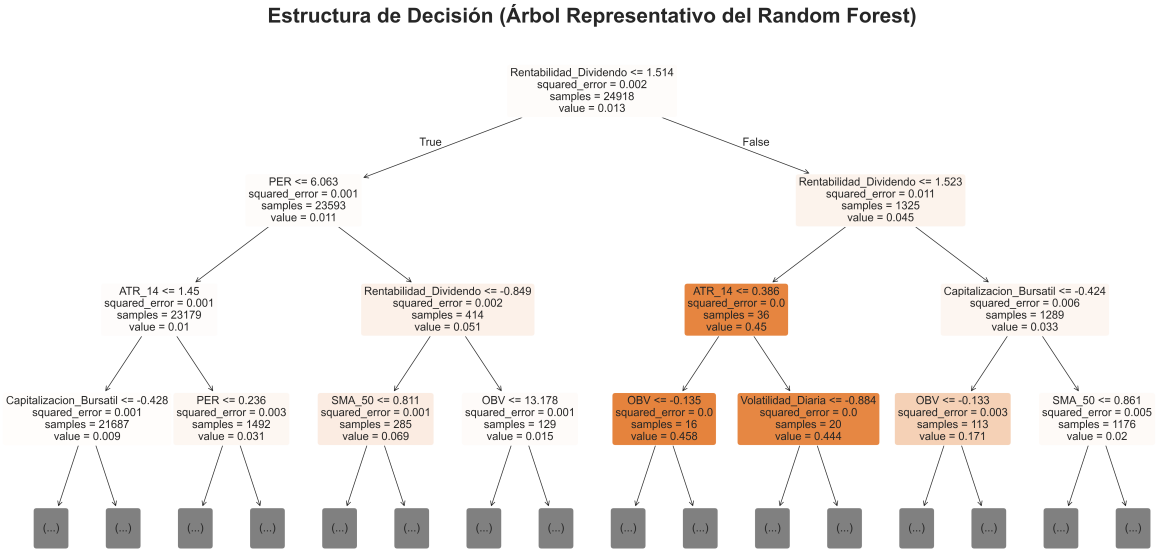
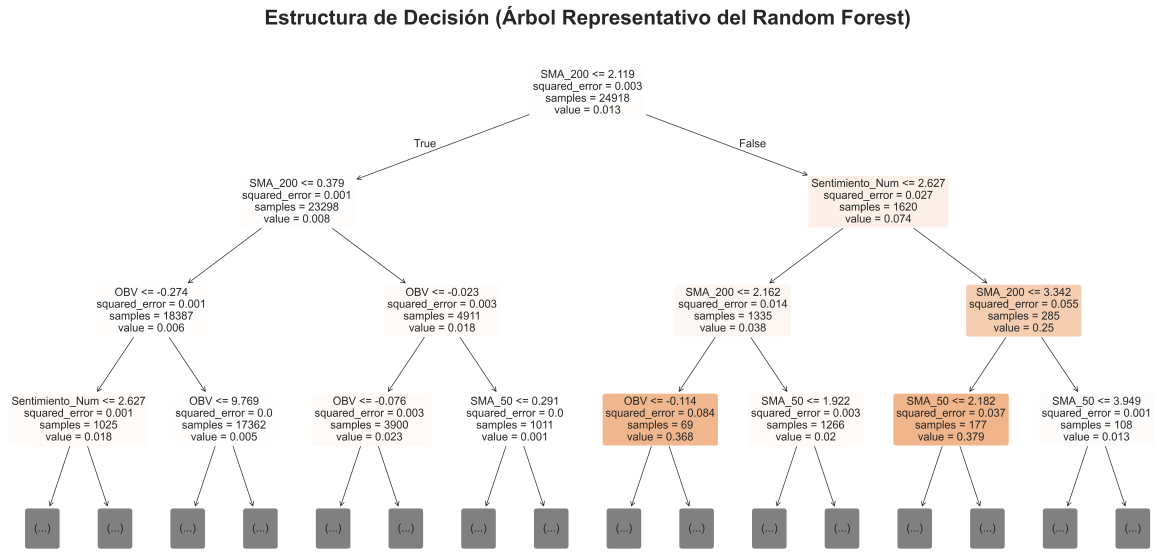


Figura 8.9: Evolución Temporal de la Cartera

Fuente: Elaboración propia.



(a) Muestra de un árbol de decisión representativo del Modelo Base.



(b) Muestra de un árbol de decisión representativo del Modelo Dinámico.

Figura 8.10: Arboles representativos del Modelo Sustituto: a) Modelo Base y b) Modelo Dinámico.

Fuente: Elaboración propia.